Estratégia Concursos

Aula 08

DataPrev (Analista de TI - Desenvolvimento de Software) Passo Estratégico de Conhecimentos Específicos - 2024 (Pós-Edital)

Autor:

09 de Setembro de 2024

11225354498 - Maria Vitória Gonçalves Vieira

DATA MINING

Sumário

Conteúdo 1

Glossário de termos 3

Roteiro de revisão 6

- Introdução e Motivação 6
- Conceitos e Definições 7
- Objetivos 10
- Processo de Mineração de Dados 11
- Técnicas de Pré-Processamento (Preparação de Dados) 20
- Técnicas de Mineração de Dados 26
- Mineração de Texto 33

Aposta estratégica 36

Questões Estratégicas 37

Questionário de revisão e aperfeiçoamento 40

- Perguntas 41
- Perguntas e Respostas 43

Lista de Questões Estratégicas 48

CONTEÚDO

Mineração de Dados. Conceitos fundamentais. Definições. Objetivos. Processos.

11225354498 - Maria Vitória Gonçalves Vieira

ANÁLISE ESTATÍSTICA

Inicialmente, convém destacar o percentual de incidência do assunto, dentro da disciplina **Banco de Dados e Business Intelligence** em concursos/cargos similares. Quanto maior o percentual de cobrança de um dado assunto, maior sua importância.

Obs.: *um mesmo assunto pode ser classificado em mais de um tópico devido à multidisciplinaridade de conteúdo*.

Assunto	Relevância na disciplina em concursos similares
SQL	**21.6 %**
BI (Business Intelligence)	**9.0 %**
DW - Data Warehouse	**7.2 %**
SQL Server	**7.2 %**
Oracle	**6.3 %**
Banco de Dados Multidimensionais	**5.4 %**
Data Mining	**5.4 %**
Administração de banco de dados	**3.6 %**
Banco de Dados	**2.7 %**
Formas normais	**2.7 %**
ETL (Extract Transform Load)	**2.7 %**
Banco de Dados Relacionais	**2.7 %**
Arquitetura de Banco de Dados	**1.8 %**
SGBD - Sistema de Gerenciamento de Banco de Dados	**1.8 %**
OLAP (On-line Analytical Processing)	**1.8 %**
Segurança	**1.8 %**
MS-Access	**1.8 %**
Modelo relacional	**1.8 %**
Metadados e Metainformação	**1.8 %**
Álgebra relacional	**0.9 %**
Banco de Dados Paralelos e Distribuídos	**0.9 %**
Gerência de Transações	**0.9 %**
Modelagem de dados	**0.9 %**
Gatilhos (Triggers)	**0.9 %**
DER - Diagrama de Entidade e Relacionamento	**0.9 %**
Visão (View)	**0.9 %**
Banco de Dados Textuais	**0.9 %**
Índices	**0.9 %**
PostgreSQL	**0.9 %**



MySQL	**0.9 %**
Big Data	**0.9 %**

GLOSSÁRIO DE TERMOS

Faremos uma lista de termos que são relevantes ao entendimento do assunto desta aula. Caso tenha alguma dúvida durante a leitura, esta seção pode lhe ajudar a esclarecer.

Mineração de dados: É a área da ciência da computação que tem como objetivo descobrir padrões e informações úteis a partir de grandes volumes de dados.

Previsão: Técnica utilizada na mineração de dados para fazer estimativas ou projeções sobre um evento ou resultado futuro com base em dados históricos.

Identificação: Processo de identificar características ou propriedades de um conjunto de dados, com o objetivo de extrair informações úteis para tomada de decisões.

Classificação: Técnica de mineração de dados que consiste em separar um conjunto de dados em diferentes categorias ou classes com base em características específicas.

Otimização: Processo de encontrar a melhor solução ou conjunto de soluções para um problema específico de acordo com critérios definidos.

Processo de Mineração de Dados: Sequência de etapas seguidas para realizar uma tarefa de mineração de dados, que inclui desde a seleção e preparação dos dados até a interpretação e apresentação dos resultados. O processo de mineração de dados mais utilizado é o CRISP-DM, que inclui seis etapas: entendimento do negócio, entendimento dos dados, preparação dos dados, modelagem, avaliação e implantação.

Entendimento do Negócio (CRISP-DM): Etapa inicial do modelo CRISP-DM, onde são identificados os objetivos do projeto e o contexto em que ele se insere. É importante entender as necessidades dos usuários finais e definir as metas do projeto, para garantir que os resultados da mineração de dados sejam relevantes e úteis.

Compreensão dos Dados (CRISP-DM): Etapa do CRISP-DM onde os dados são explorados e analisados para entender melhor sua qualidade, estrutura e relacionamentos. A Compreensão dos Dados ajuda a identificar problemas nos dados e a definir estratégias de pré-processamento para melhorá-los e prepará-los para a fase de modelagem.

Preparação dos Dados (CRISP-DM): Etapa do modelo CRISP-DM onde os dados são preparados para análise e modelagem, incluindo tarefas como seleção de variáveis, limpeza, transformação e integração de dados. Essa etapa é crítica para garantir que os dados estejam em um formato adequado para análise e que as suposições feitas pelo modelo sejam válidas.

Modelagem dos Dados (CRISP-DM): Etapa do CRISP-DM onde os modelos de mineração de dados são construídos e avaliados. Isso inclui a escolha de algoritmos, definição de parâmetros, ajuste do modelo e validação. O objetivo é desenvolver modelos precisos e robustos que possam ser usados para fazer previsões ou identificar padrões nos dados.

Avaliação (CRISP-DM): Etapa final do modelo CRISP-DM, onde os modelos desenvolvidos na etapa anterior são avaliados quanto à sua eficácia e eficiência. Isso inclui a análise de métricas de desempenho e a comparação dos modelos com os objetivos do projeto. Os resultados dessa avaliação podem levar à revisão do modelo ou à sua aceitação.

Entrega (CRISP-DM): Última etapa do modelo CRISP-DM, onde os resultados da mineração de dados são entregues aos usuários finais. Isso inclui a apresentação dos resultados de forma clara e compreensível, além da documentação do processo de mineração de dados para permitir a replicação dos resultados. A Entrega é importante para garantir que os resultados da mineração de dados sejam utilizados de forma efetiva e gerem valor para o negócio.

Incompletude: Falta de informação ou dados ausentes em uma base de dados.

Inconsistência: Conflitos ou discrepâncias entre os dados de uma base de dados, que podem ser causados por erros humanos ou falhas no processo de coleta de dados.

Ruído: Dados que possuem erros aleatórios, que podem afetar negativamente a precisão da análise dos dados.

Limpeza de dados (pré-processamento): Técnica de pré-processamento que visa remover ruídos, inconsistências e dados incompletos de uma base de dados para prepará-la para análises mais precisas.

Integração (pré-processamento): Técnica de pré-processamento que envolve a combinação de múltiplas fontes de dados em uma única base de dados, com o objetivo de obter informações mais abrangentes e completas.

Transformação (pré-processamento): Técnica de pré-processamento que envolve a modificação dos dados em uma base de dados para torná-los mais adequados para análise, como por exemplo, a normalização de valores numéricos.

11225354498 - Maria Vitória Gonçalves Vieira

Redução (pré-processamento): Técnica de pré-processamento que envolve a redução da quantidade de dados em uma base de dados, removendo informações redundantes ou irrelevantes.

Discretização (pré-processamento): Técnica de pré-processamento que envolve a transformação de variáveis contínuas em variáveis discretas, para facilitar a análise e reduzir o impacto do ruído nos dados.

Associação (técnica de mineração): Técnica de mineração de dados que visa descobrir relações entre variáveis em uma base de dados, como por exemplo, a descoberta de produtos frequentemente comprados juntos em um e-commerce.

Classificação (técnica de mineração): Técnica de mineração de dados que visa classificar objetos em diferentes categorias, com base em suas características, como por exemplo, a classificação de e-mails como spam ou não spam.

Agrupamento (técnica de mineração): Técnica de mineração de dados que visa agrupar objetos em clusters ou grupos, com base em suas similaridades, como por exemplo, a segmentação de clientes em grupos com base em suas preferências de compra.

Mineração de Texto (técnica de mineração): Técnica de mineração de dados que envolve a análise de dados em formato de texto, como e-mails, posts em redes sociais ou artigos de notícias.

Thesaurus (mineração de texto): Um thesaurus é um conjunto de palavras-chave organizadas em categorias hierárquicas e relacionadas por sinônimos e antônimos, utilizado para melhorar a precisão da busca e classificação de documentos em uma base de dados.

Case Folding (mineração de texto): Técnica de normalização de texto que converte todas as letras de um texto para minúsculas, a fim de eliminar a diferenciação de palavras escritas com letras maiúsculas e minúsculas.

Stop Words (mineração de texto): Palavras comuns em um idioma que são removidas durante a análise de texto, pois não têm impacto significativo na análise, como por exemplo, artigos e preposições em português.

Stemming (mineração de texto): Técnica de normalização de texto que reduz as palavras à sua forma raiz, ou seja, a forma básica ou radical da palavra. Por exemplo, as palavras "amigo", "amiga", "amigos" e "amigas" têm a mesma raiz "amig", portanto, seriam reduzidas a essa forma raiz durante o processo de stemming.

11225354498 - Maria Vitória Gonçalves Vieira

ROTEIRO DE REVISÃO

A ideia desta seção é apresentar um roteiro para que você realize uma revisão completa do assunto e, ao mesmo tempo, destacar aspectos do conteúdo que merecem atenção.

Introdução e Motivação

Mineração de Dados, também conhecida como Descoberta de Conhecimento em Bancos de Dados (KDD - Knowledge Discovery in Databases), é um processo que consiste em **extrair informações úteis e relevantes a partir de grandes conjuntos de dados**, por meio de técnicas e algoritmos de análise de dados.

A principal motivação vem da necessidade de lidar com o grande volume de dados gerados diariamente por organizações, empresas e dispositivos eletrônicos, que são armazenados em bancos de dados. Esses dados podem conter informações valiosas que podem ser usadas para obter insights e tomar decisões mais informadas e precisas em diferentes áreas, como marketing, finanças, saúde, segurança, entre outras.

A Mineração permite descobrir padrões, tendências e relacionamentos ocultos nos dados que podem não ser perceptíveis à primeira vista. Essas descobertas ajudam empresas a identificar oportunidades de negócios, antecipar tendências, prever comportamentos e melhorar a eficiência dos processos.

Por fim, pode ser útil para a detecção de fraudes, a identificação de ameaças à segurança e a análise de riscos, entre outras aplicações, além de ser uma ferramenta para transformar grandes quantidades de dados em informações úteis e práticas.

Conceitos e Definições

Mineração de dados é um processo automatizado **de explorar e analisar grandes volumes de dados com o objetivo de descobrir informações ocultas, padrões, correlações, tendências e relações entre os dados que podem ser usados para obter insights e conhecimentos úteis**.

O processo geralmente envolve várias etapas, como **coleta de dados, pré-processamento, transformação de dados, modelagem, avaliação e interpretação dos resultados**. Cada

11225354498 - Maria Vitória Gonçalves Vieira

uma dessas etapas é projetada para lidar com os problemas específicos de trabalhar com grandes conjuntos de dados e extrair informações úteis deles.

Durante o processo de mineração de dados, são utilizadas várias técnicas e algoritmos de análise de dados, como **classificação, agrupamento, associação, regressão e detecção de anomalias**, para identificar padrões e relações nos dados.

Sua utilização é amplamente aplicada em diversas áreas, como negócios, marketing, saúde, finanças, governo, entre outras, para obter insights valiosos e tomar decisões mais informadas e precisas com base nos dados disponíveis.

Veja outras definições de mineração de dados **que já foram cobradas em prova**:

Definição	Palavras-chave
Data Mining é o processo de explorar grande quantidade de dados para extração não-trivial de informação implícita desconhecida.	**exploração; informação implícita desconhecida.**
Data Mining é uso de teorias, métodos, processos e tecnologias para organizar uma grande quantidade de dados brutos para identificar padrões de comportamentos em determinados públicos.	**teorias; métodos; processos; tecnologias; organizar dados brutos; padrões de comportamentos.**
Data Mining é a categoria de ferramentas de análise denominada open-end e que permite ao usuário avaliar tendências e padrões não conhecidos entre os dados.	**ferramenta de análise; open-end; tendências e padrões.**
Data Mining é o processo de descoberta de novas correlações, padrões e tendências entre as informações de uma empresa, por meio da análise de grandes quantidades de dados armazenados em bancos de dados usando técnicas de reconhecimento de padrões, estatísticas e matemáticas.	**descoberta; correlações; padrões; tendências; reconhecimento de padrões; estatística; matemática**
Data Mining constitui em uma técnica para a exploração e análise de dados, visando descobrir padrões e regras, a princípio ocultos, importantes à aplicação	**exploração e análise de dados; padrões; regras; ocultos.**
Data Mining é o conjunto de ferramentas que permitem ao usuário avaliar tendências e padrões não conhecidos entre os dados. Esses tipos de ferramentas podem utilizar técnicas	**tendências; padrões; redes neurais; algoritmos genéticos; lógica nebulosa.**

11225354498 - Maria Vitória Gonçalves Vieira

avançadas de computação como redes neurais, algoritmos genéticos e lógica nebulosa (fuzzy), dentre outras.	
Data Mining é um método computacional que permite extrair informações a partir de grande quantidade de dados.	**Extração**
Data Mining é o processo de identificar, em dados, padrões válidos, novos, potencialmente úteis e, ao final, compreensíveis.	**Utilidade**
Data Mining é o conjunto de ferramentas e técnicas de mineração de dados que têm por objetivo buscar a classificação e o agrupamento (clusterização) de dados, bem como identificar padrões	**Ferramentas e técnicas**
Data Mining é o processo de explorar grandes quantidades de dados à procura de padrões consistentes com o intuito de detectar relacionamentos sistemáticos entre variáveis e novos subconjuntos de dados.	**padrões; relacionamentos.**
Data Mining consiste em explorar um conjunto de dados visando a extrair ou a ajudar a evidenciar padrões, como regras de associação ou sequências temporais, para detectar relacionamentos entre estes.	**exploração; padrões; regras; associação; sequência temporal; detecção.**
Data Mining são ferramentas que utilizam diversas técnicas de natureza estatística, como a análise de conglomerados (cluster analysis), que tem como objetivo agrupar, em diferentes conjuntos de dados, os elementos identificados como semelhantes entre si, com base nas características analisadas.	**estatística; análise de conglomerados; agrupamento.**
Data Mining é o conjunto de técnicas que, envolvendo métodos matemáticos e estatísticos, algoritmos e princípios de inteligência artificial, tem o objetivo de descobrir relacionamentos significativos entre dados armazenados em repositórios de grandes volumes e concluir sobre padrões de comportamento de clientes de uma organização.	**métodos matemáticos e estatístico; inteligência artificial; relacionamentos; padrões; comportamentos.**
Data Mining é o processo de explorar grandes quantidades de dados à procura de padrões consistentes, como regras de associação ou sequências temporais, para detectar	**padrões; regras de associação; sequências temporais; relacionamentos.**

11225354498 - Maria Vitória Gonçalves Vieira

relacionamentos sistemáticos entre variáveis, detectando assim novos subconjuntos de dados.	
Data Mining é o processo de explorar grandes quantidades de dados à procura de padrões consistentes, como regras de associação ou sequências temporais.	**exploração; padrões consistentes; regras de associação; sequência temporal.**
Data Mining é o processo de analisar de maneira semiautomática grandes bancos de dados para encontrar padrões úteis.	**padrões**

Objetivos

Ramez Elmasri e Shamkant B. Navathe, autores do livro "Sistemas de Banco de Dados", descrevem os objetivos da Mineração de Dados como sendo:

Previsão: a previsão é usada para identificar e prever eventos futuros com base em padrões históricos encontrados nos dados. É uma técnica comumente usada em áreas como finanças, marketing e ciência de dados.

Identificação: a identificação é usada para descobrir padrões, relações e associações entre os dados que podem não ser óbvias à primeira vista. Esses padrões podem ser usados para identificar oportunidades de negócios, antecipar tendências e melhorar a eficiência dos processos.

Classificação: a classificação é usada para categorizar os dados em diferentes grupos com base em características comuns. É uma técnica amplamente usada em áreas como marketing e análise de risco, onde é necessário agrupar os dados em diferentes categorias para tomar decisões mais informadas.

Otimização: a otimização é usada para encontrar o melhor valor possível de uma variável ou conjunto de variáveis, sujeita a um conjunto de restrições. É uma técnica amplamente usada em áreas como engenharia, finanças e logística, onde é necessário encontrar a solução mais eficiente para um determinado problema.

Cada um desses objetivos pode ser alcançado por meio de diferentes técnicas e algoritmos de análise de dados, dependendo dos dados disponíveis e dos objetivos do projeto.

11225354498 - Maria Vitória Gonçalves Vieira

Processo de Mineração de Dados

CRISP-DM (Cross Industry Standard Process for Data Mining) é um modelo de processo de mineração de dados amplamente utilizado para guiar as equipes de projeto durante a execução de projetos de mineração de dados. O modelo CRISP-DM é composto por **seis etapas principais**:

Etapa do CRISP-DM	Descrição	Exemplo
Entendimento do negócio	**Nesta etapa, a equipe de projeto define o objetivo do projeto de mineração de dados, as questões a serem respondidas e os requisitos do negócio. É importante garantir que os resultados da mineração de dados sejam relevantes e úteis para o negócio.**	**Uma empresa de comércio eletrônico deseja prever a taxa de conversão dos usuários em compradores para melhorar suas campanhas de marketing.**
Entendimento dos dados	**Nesta etapa, a equipe de projeto coleta e explora os dados relevantes para o projeto de mineração de dados. A análise dos dados é realizada para entender as características dos dados e identificar problemas de qualidade.**	**A empresa coleta dados de atividades de usuários, como tempo de sessão, páginas visitadas e produtos visualizados.**
Preparação dos dados	**Nesta etapa, os dados são pré-processados, limpos e transformados em um formato adequado para a modelagem. Isso pode envolver a seleção de recursos, a transformação de dados categóricos em numéricos e a normalização dos dados.**	**A equipe remove dados faltantes, transforma dados categóricos em numéricos e normaliza os dados de tempo de sessão.**
Modelagem	**Nesta etapa, são aplicadas técnicas de modelagem de dados, como regressão, classificação, clusterização e associação, para identificar padrões e tendências nos dados.**	**A equipe aplica um modelo de regressão logística para prever a probabilidade de conversão dos usuários.**

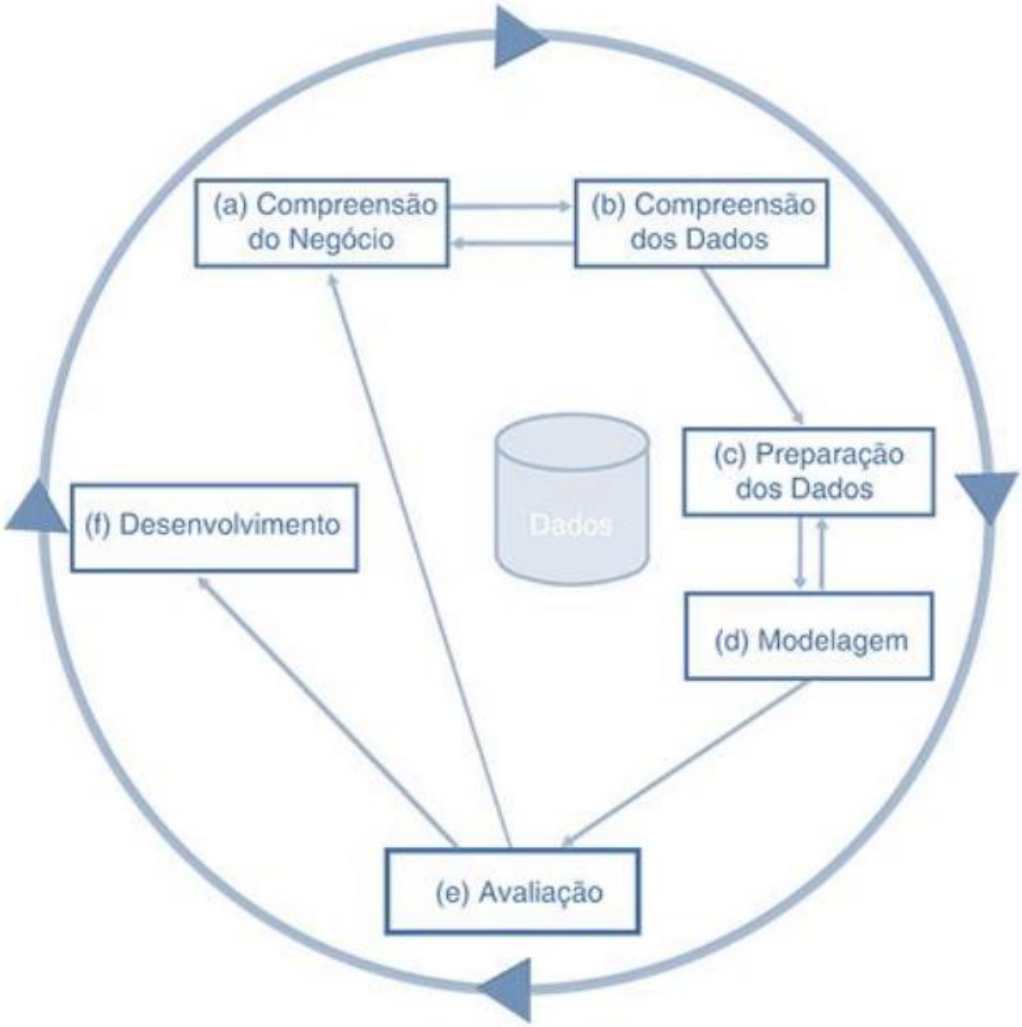
11225354498 - Maria Vitória Gonçalves Vieira

Avaliação	**Nesta etapa, os modelos são avaliados e validados para determinar sua precisão e eficácia. Isso pode incluir a avaliação do desempenho do modelo em dados de treinamento e teste, a comparação de diferentes modelos e a análise de sensibilidade.**	**A equipe avalia o modelo em um conjunto de dados de teste e compara o desempenho com outros modelos de regressão.**
Implantação	**Nesta etapa, os resultados da mineração de dados são implantados no ambiente de negócios e integrados aos processos de tomada de decisão.**	**A empresa integra as previsões de conversão em suas campanhas de marketing para segmentar usuários com maior probabilidade de converter em compradores.**

Veja a figura abaixo que representa as seis etapas do CRISP-DM:

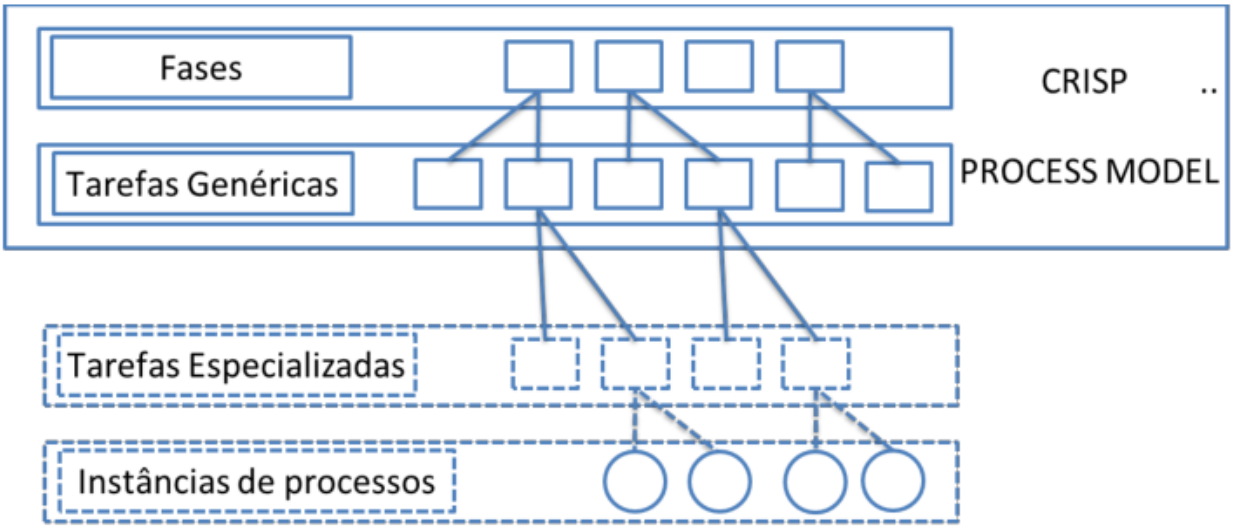
Obs.: há um erro de tradução abaixo - a etapa "F" se chama "Deployment", que significa "Entrega" (traduziram para "Development" que significa "Desenvolvimento" - outra coisa).

11225354498 - Maria Vitória Gonçalves Vieira



É importante lembrar que o CRISP-DM é um processo iterativo, ou seja, as equipes de projeto podem precisar revisitar as etapas anteriores à medida que novas informações e insights são descobertos durante o processo de mineração de dados. O modelo é flexível e pode ser adaptado para diferentes projetos e necessidades de negócios.

Além disso, a metodologia CRISP-DM costuma ser organizada em quatro níveis hierárquicos como podemos visualizar na figura abaixo:



No primeiro nível, o processo de mineração de dados é organizado em várias **fases**. Cada fase consiste em várias tarefas genéricas de segundo nível.

O segundo nível é chamado genérico porque pretende ser geral o suficiente para cobrir todas as situações possíveis de mineração de dados. As **tarefas genéricas** devem ser o mais completas e estáveis possível. Por completos queremos dizer que abrangem todo o processo de mineração de dados e todos os aplicativos possíveis de mineração de dados. Já estável significa que o modelo deve ser válido para desenvolvimentos de modelos imprevisíveis, utilizando novas técnicas de modelagem.

O terceiro nível, o nível de **tarefa especializada**, é o local para descrever como as ações das tarefas

genéricas devem ser realizadas em determinadas situações específicas. Por exemplo, no segundo nível, pode haver uma tarefa genérica chamada limpeza dos dados. O terceiro nível descreveria como essa tarefa é executada em diferentes situações, como limpeza de valores numéricos, de valores categóricos.

11225354498 - Maria Vitória Gonçalves Vieira

A descrição de fases e tarefas como etapas discretas executadas em uma ordem específica representa uma sequência idealizada de eventos. Na prática, muitas das tarefas podem ser executadas em uma ordem diferente e, muitas vezes, será necessário voltar repetidamente às tarefas anteriores e repetir determinadas ações. O modelo de processo não tenta capturar todas essas rotas possíveis por meio do processo de mineração de dados, porque isso exigiria um modelo de processo excessivamente complexo.

O quarto, e último, nível, a **instância do processo**, é um registro das ações, decisões e resultados de um compromisso real de mineração de dados. Uma instância do processo é organizada de acordo com as tarefas definidas nos níveis mais altos, mas representa o que realmente aconteceu em um determinado engajamento, e não o que acontece em geral.

Entendimento do Negócio (CRISP-DM - Etapa 1)

Entendimento do Negócio (ou Business Understanding) é a primeira etapa do modelo CRISP-DM e consiste em uma **série de atividades para se obter um entendimento completo do problema de negócio** que se deseja abordar.

Nessa etapa, a equipe de mineração de dados deve trabalhar em estreita colaboração com os especialistas em negócios para compreender completamente as metas, objetivos e requisitos do projeto. É importante para a equipe identificar o escopo do problema de negócio, as necessidades dos usuários, as restrições e limitações envolvidas, e a forma como o modelo de mineração de dados pode ser usado para solucionar o problema.

Algumas das tarefas comuns realizadas durante esta etapa incluem:

Determinar os objetivos do projeto e as metas de negócios: Envolve identificar claramente o que a empresa espera alcançar ao utilizar a mineração de dados, como redução de custos, aumento de receita, aumento da eficiência, entre outros.

Avaliar a situação atual: Identificar as limitações técnicas, orçamentárias e de pessoal. Além disso, a equipe deve entender o ambiente de negócios atual e como o projeto de mineração de dados se encaixa nesse contexto.

Identificar os requisitos do projeto: Nesta etapa, a equipe deve identificar os requisitos funcionais e não-funcionais do projeto, como necessidades de dados, requisitos de desempenho e requisitos de segurança.

11225354498 - Maria Vitória Gonçalves Vieira

Definir as premissas do projeto: A equipe de mineração de dados deve estabelecer as premissas do projeto, como os dados que estarão disponíveis, a qualidade desses dados e as limitações técnicas.

Ao final dessa etapa, a equipe deve ter uma compreensão clara do problema de negócio, bem como das expectativas e objetivos do projeto. A partir daí, a equipe pode começar a planejar a abordagem de mineração de dados mais adequada para atingir esses objetivos.

Compreensão dos Dados (CRISP-DM - Etapa 2)

Compreensão dos Dados é a segunda etapa do processo CRISP-DM e é fundamental para a criação de um modelo de mineração de dados preciso e eficaz. Essa etapa envolve a coleta e exploração dos dados relevantes para o projeto.

A seguir estão as principais tarefas associadas à etapa de Compreensão dos Dados:

Descrever os dados: nesta tarefa, o objetivo é entender a natureza dos dados coletados. É importante conhecer as características dos dados, como tamanho, formato, tipos de variáveis, etc. Isso ajuda a identificar possíveis problemas ou limitações nos dados, como valores ausentes ou dados inconsistentes.

Explorar os dados: aqui, o objetivo é explorar os dados coletados para entender melhor suas características e padrões. Isso pode incluir a visualização dos dados em gráficos, a realização de análises estatísticas simples e a identificação de relações entre as variáveis.

Verificar a qualidade dos dados: o objetivo é garantir que os dados coletados estejam limpos e prontos para serem usados na criação do modelo de mineração de dados. Isso pode incluir a verificação de valores ausentes, a remoção de dados duplicados ou inconsistentes e a correção de erros nos dados.

Documentar os resultados: nesta tarefa, procura-se documentar todas as descobertas relevantes na etapa de Compreensão dos Dados. Isso pode incluir a descrição dos dados coletados, os principais padrões identificados e quaisquer limitações ou problemas nos dados.

Preparação dos Dados (CRISP-DM - Etapa 3)

11225354498 - Maria Vitória Gonçalves Vieira

A etapa de Preparação dos Dados é a terceira fase do modelo CRISP-DM. Nessa fase, os dados são preparados para serem usados nas próximas etapas do processo de mineração de dados.

Essa fase é importante porque muitas vezes os dados disponíveis não estão prontos para serem usados diretamente. Os dados podem estar incompletos, conter erros, ser redundantes, estar em formatos diferentes ou simplesmente não estar disponíveis em um formato adequado para a mineração de dados.

Principais tarefas:

Coleta dos dados: Coletar os dados de diversas fontes, incluindo bancos de dados, arquivos e sistemas.

Limpeza dos dados: Limpar os dados, removendo valores ausentes, valores duplicados, erros e outliers.

Integração dos dados: Integrar os dados de diferentes fontes para criar uma visão única dos dados.

Transformação dos dados: Transformar os dados para uma forma que seja adequada para a análise. Por exemplo, converter dados categóricos em numéricos ou normalizar os dados para eliminar discrepâncias de escala.

Seleção dos dados: Selecionar os dados que serão usados na análise, removendo os dados que não são relevantes ou não são necessários para a análise.

Criação de dados derivados: Criar novos dados a partir dos dados existentes, como calcular médias, desvios padrão ou criar novas variáveis com base nas existentes.

Formatação dos dados: Formatar os dados para uso em algoritmos específicos de mineração de dados.

Ao final desta fase, espera-se que os dados estejam prontos para a próxima etapa, que é a modelagem.

Modelagem dos Dados (CRISP-DM - Etapa 4)

Modelagem dos Dados é a quarta etapa do CRISP-DM. Nesta etapa, os dados preparados na etapa anterior são utilizados para criar modelos que permitam alcançar os objetivos definidos na etapa de Entendimento do Negócio.

11225354498 - Maria Vitória Gonçalves Vieira

Os principais objetivos desta etapa são:

- Selecionar a técnica de modelagem mais adequada para o problema em questão.
- Gerar um ou mais modelos candidatos.
- Avaliar os modelos gerados e selecionar aquele que melhor atende aos objetivos definidos.

A seleção da técnica de modelagem depende dos objetivos do projeto, da natureza dos dados e das habilidades da equipe responsável pelo projeto. Algumas técnicas de modelagem amplamente utilizadas incluem: árvores de decisão, redes neurais, regressão, análise discriminante, entre outras.

Após selecionar a técnica de modelagem, é necessário gerar um ou mais modelos candidatos. Esses modelos são ajustados e refinados com base nos resultados obtidos em avaliações subsequentes. Para avaliar os modelos gerados, são utilizadas técnicas como validação cruzada, teste de conjunto de dados de treinamento e teste de conjunto de dados de validação.

A escolha do melhor modelo é feita com base em métricas de desempenho, como precisão, recall, F1-score, AUC-ROC, entre outras. A seleção do modelo final depende dos critérios definidos na etapa de Entendimento do Negócio.

Uma vez selecionado o modelo final, ele é documentado e entregue aos usuários ou às equipes responsáveis por implementá-lo em um ambiente de produção.

Avaliação (CRISP-DM - Etapa 5)

A etapa de Avaliação é onde se analisa os modelos gerados na etapa de Modelagem, a fim de **avaliar sua qualidade e identificar possíveis problemas**. Nessa etapa, busca-se determinar se os modelos criados são satisfatórios para resolver o problema de negócio identificado na etapa de Entendimento do Negócio. Além disso, a avaliação dos modelos deve ser feita em relação aos critérios estabelecidos na etapa de Compreensão dos Dados.

Algumas das atividades que podem ser realizadas na etapa de Avaliação são:

- Avaliação da qualidade dos modelos gerados;
- Análise dos resultados obtidos pelos modelos;
- Comparação dos modelos gerados com outros modelos ou soluções já existentes;
- Verificação de se o modelo está atendendo aos requisitos do negócio;
- Identificação de possíveis problemas ou limitações do modelo.

11225354498 - Maria Vitória Gonçalves Vieira

Com base nas análises e avaliações realizadas nessa etapa, é possível decidir se é necessário ajustar os modelos ou se eles estão prontos para serem implantados no ambiente de produção. Caso seja necessário ajustar os modelos, é preciso retornar à etapa de Modelagem para fazer as mudanças necessárias. Se o modelo estiver satisfatório, é possível implantá-lo no ambiente de produção na etapa de Implementação.

Entrega (CRISP-DM - Etapa 6)

Entrega é a última fase do processo de mineração de dados, que envolve a implantação do modelo desenvolvido para uso em um ambiente operacional e o monitoramento do seu desempenho. Nesta fase, o modelo é entregue ao cliente ou usuário final.

As principais atividades da etapa de Entrega incluem:

Planejamento da implantação: nesta atividade, é definido o plano de implantação do modelo em um ambiente de produção. Isso inclui a definição das configurações de hardware e software necessárias, a identificação dos recursos necessários e a definição de prazos.

Preparação para a implantação: aqui são preparados todos os componentes necessários para a implantação do modelo, como o código-fonte do modelo, scripts para instalação e configuração, documentação e treinamento para os usuários.

Implantação do modelo: o modelo é instalado e configurado no ambiente de produção. É importante garantir que todas as configurações estejam corretas e que o modelo seja capaz de operar adequadamente.

Monitoramento do desempenho: o desempenho do modelo é monitorado em tempo real para garantir que ele esteja funcionando corretamente e fornecendo resultados precisos. Qualquer problema ou desvio do desempenho esperado deve ser identificado e corrigido o mais rápido possível.

Manutenção e atualização: o modelo é mantido e atualizado conforme necessário. Isso inclui a correção de problemas, a atualização de dados, a atualização de software e hardware e a adaptação do modelo a novos requisitos ou necessidades do usuário.

Documentação e treinamento: nesta atividade, são criados e atualizados todos os documentos e treinamentos necessários para ajudar os usuários a entender e utilizar o modelo de forma eficaz e eficiente.

11225354498 - Maria Vitória Gonçalves Vieira

A entrega bem-sucedida do modelo é essencial para o sucesso de todo o processo de mineração de dados, pois é aqui que o modelo é colocado em operação e começa a fornecer informações úteis e acionáveis para o negócio.

Técnicas de Pré-Processamento (Preparação de Dados)

Nesta parte da aula vamos apresentar algumas técnicas que nos permitem fazer ajustes nos dados para facilitar a mineração, bem como para garantir que a síntese feita sobre os dados produza alguma informação consistente.

Os dados no mundo real são "sujos", ou seja, podem, por exemplo, estarem incompletos com valores faltantes, atributos faltantes. Outra possibilidade é a existência de ruídos, que provocam erros ou outliers sobre os dados. Por fim, podemos verificar a consistência entre atributos, por exemplo, os atributos data de nascimento e idade precisam ser compatíveis. Uma pessoa que nasceu em 1983 não pode ter, em 2017, 50 anos.

Problemas nos dados podem ter várias origens e causas. Entre as mais comuns, destacam-se a incompletude, a inconsistência e o ruído:

A incompletude refere-se à falta de informações em alguns registros ou atributos dos dados. Isso pode ocorrer por vários motivos, como falhas na coleta, perda de informações ou mesmo a recusa do usuário em fornecer determinados dados.

A inconsistência ocorre quando há conflitos entre os dados, ou seja, quando diferentes registros ou atributos apresentam informações conflitantes ou incompatíveis entre si. Por exemplo, um cadastro de clientes pode apresentar informações diferentes para um mesmo cliente, como endereços diferentes em registros distintos.

O ruído refere-se à presença de informações irrelevantes ou incorretas nos dados. Isso pode ser causado por vários fatores, como erros de digitação, falhas na coleta ou até mesmo a presença de informações falsas ou intencionalmente manipuladas. O ruído pode prejudicar a qualidade dos dados e dificultar a identificação de padrões e insights relevantes.

As técnicas de pré-processamento de dados são um conjunto de técnicas que visam preparar os dados para serem utilizados em análises ou em modelos de mineração de dados. A motivação para utilizar essas técnicas é a de melhorar a qualidade dos dados, eliminando problemas como incompletude, inconsistência e ruído, bem como tornar os dados mais adequados para a análise ou modelagem.

Entre os benefícios das técnicas de pré-processamento de dados, podemos destacar:



11225354498 - Maria Vitória Gonçalves Vieira

Melhoria da qualidade dos dados: As técnicas de pré-processamento permitem eliminar erros e inconsistências nos dados, melhorando sua qualidade e confiabilidade.

Aumento da precisão dos modelos: Dados incompletos, inconsistentes ou ruidosos podem prejudicar a precisão dos modelos de mineração de dados. O pré-processamento pode ajudar a eliminar esses problemas e, consequentemente, melhorar a precisão dos modelos.

Redução do tempo de processamento: Dados desnecessários ou duplicados podem aumentar o tempo de processamento. O pré-processamento permite eliminar esses dados, reduzindo o tempo de processamento.

Maior eficiência na análise de dados: Dados bem-preparados e estruturados tornam a análise mais eficiente e precisa, permitindo que sejam obtidas informações úteis a partir dos dados com maior facilidade e rapidez.

Para alcançar esses benefícios, faz-se necessária a execução de um conjunto de tarefas de pré-processamento de dados.

Vejamos:

Tarefa	Descrição	Exemplo
Limpeza de Dados	**Remoção de dados incompletos, inconsistentes ou com ruído**	**Remover registros com valores nulos ou preencher valores faltantes com uma estimativa adequada**
Integração	**Combinação de múltiplas fontes de dados em um único conjunto de dados**	**Combinar dados de vendas de diferentes filiais de uma empresa em um único conjunto de dados**
Transformação	**Conversão de dados brutos em uma forma mais adequada para mineração**	**Normalização de valores numéricos em uma escala comum para evitar viés devido a unidades de medida diferentes**
Redução	**Redução do tamanho do conjunto de dados, mantendo o máximo de informações relevantes**	**Selecionar as características mais importantes dos dados para a análise de dados**

11225354498 - Maria Vitória Gonçalves Vieira

Discretização	**Transformação de atributos numéricos em categóricos**	**Converter a idade de uma pessoa em grupos etários, como 20-30, 30-40, 40-50 anos**

Tratamento de Valores Faltantes (Preparação de Dados)

Tratamento de valores faltantes é uma técnica de pré-processamento de dados que lida com dados ausentes em um conjunto de dados. Valores faltantes podem ocorrer por diferentes motivos, como erros de coleta de dados, falhas de sensores, perda de dados durante a transferência ou simplesmente porque algumas informações não foram registradas.

Lidar adequadamente com valores faltantes é importante para garantir que os dados sejam confiáveis e adequados para análise. Existem diferentes abordagens para tratar valores faltantes, dependendo da natureza dos dados e do contexto do problema. Alguns métodos comuns são:

Exclusão de registros ou atributos: uma abordagem simples é excluir os registros (linhas) que possuem valores faltantes ou os atributos (colunas) que contêm uma quantidade significativa de valores faltantes. Isso pode ser uma opção viável se os valores faltantes forem aleatórios e não houver muita perda de informação. No entanto, essa abordagem pode levar à perda de dados valiosos se os valores faltantes estiverem relacionados a outras variáveis importantes.

Preenchimento com valores médios ou medianos: nesse método, os valores faltantes são substituídos pela média ou mediana dos valores existentes na mesma variável. Essa abordagem é útil quando os dados estão distribuídos normalmente e não há muita variação nos valores. Por exemplo, se estamos tratando a idade de uma pessoa em um conjunto de dados e alguns valores estão faltando, podemos substituí-los pela média das idades conhecidas.

Preenchimento com valores interpolados: se os dados seguem uma tendência ou padrão, podemos usar a interpolação para preencher os valores faltantes. Isso envolve estimar os valores ausentes com base nos valores conhecidos próximos no tempo ou no espaço. Por exemplo, se estamos trabalhando com dados de temperatura em diferentes horas do dia e um valor está faltando, podemos usar a média entre os valores antes e depois do intervalo de tempo em questão para preencher o valor ausente.

Preenchimento com modelos preditivos: em alguns casos, podemos usar modelos preditivos, como regressão, para prever os valores faltantes com base em outros atributos

11225354498 - Maria Vitória Gonçalves Vieira

do conjunto de dados. Por exemplo, se estamos lidando com dados de vendas de produtos e o preço de alguns produtos está faltando, podemos usar um modelo de regressão com base em outros atributos, como categoria do produto e quantidade vendida, para estimar os preços ausentes.

Tratamento de Outliers (Preparação de Dados)

O tratamento de outliers é uma técnica de pré-processamento de dados que lida com valores extremos ou discrepantes em um conjunto de dados. **Outliers são valores que se desviam significativamente da maioria dos outros** valores e podem ter um impacto negativo nas análises estatísticas ou nos modelos de aprendizado de máquina.

A presença de outliers pode distorcer as estatísticas descritivas, como média e desvio padrão, afetar a normalidade dos dados e comprometer a precisão dos modelos. Portanto, é importante identificar e tratar os outliers de forma adequada. Existem algumas abordagens comuns para lidar com outliers:

Identificação visual: uma maneira inicial de identificar outliers é por meio de gráficos, como o gráfico de dispersão (scatter plot) ou o box plot. Esses gráficos podem ajudar a identificar observações que estão distantes da maioria dos outros pontos. Visualmente, os outliers podem ser identificados como pontos fora dos intervalos esperados ou com comportamento anômalo em relação aos demais dados.

Métodos estatísticos: existem várias técnicas estatísticas para identificar outliers. Alguns exemplos incluem o cálculo do desvio padrão ou a aplicação de testes estatísticos, como o teste de Grubbs ou o teste de Dixon. Esses métodos podem detectar valores que estão além de um limite estatisticamente significativo em relação aos demais dados.

Transformação de dados: em alguns casos, é possível transformar os dados para reduzir o impacto dos outliers. Por exemplo, aplicar uma transformação logarítmica nos dados pode ajudar a reduzir a influência de valores extremos. No entanto, essa abordagem deve ser usada com cautela, pois a interpretação dos resultados pode se tornar mais complexa após a transformação.

Substituição ou remoção dos outliers: dependendo do contexto e do objetivo da análise, é possível substituir os valores extremos por valores mais realistas ou removê-los completamente. A substituição pode ser feita, por exemplo, utilizando a média, mediana ou valor interpolado dos dados não outliers. A remoção de outliers pode ser apropriada quando há evidências claras de erros nos dados ou quando a análise é sensível a valores extremos.

11225354498 - Maria Vitória Gonçalves Vieira

Discretização (Preparação de Dados)

A discretização é uma técnica de pré-processamento de dados que transforma atributos contínuos em atributos discretos, ou seja, agrupa valores contínuos em intervalos ou categorias distintas. Essa técnica é útil quando desejamos simplificar a representação dos dados ou quando um algoritmo de mineração de dados requer variáveis categóricas em vez de numéricas.

Discretização baseada em intervalos iguais: nesse método, o intervalo dos valores contínuos é dividido em um número fixo de intervalos iguais. Por exemplo, se tivermos um atributo com valores entre 0 e 100 e desejamos discretizá-lo em 5 intervalos, cada intervalo terá uma amplitude de 20 unidades (0-20, 20-40, 40-60, 60-80, 80-100).

Discretização baseada em frequência: nessa abordagem, os intervalos são definidos com base na frequência dos valores. Valores contínuos são agrupados em intervalos que contêm aproximadamente o mesmo número de instâncias. Por exemplo, podemos agrupar valores em quartis, onde cada intervalo contém 25% dos dados.

Discretização baseada em limites arbitrários: essa técnica envolve a definição de limites de intervalo arbitrários com base no conhecimento do domínio ou em critérios específicos. Por exemplo, podemos definir intervalos com base em faixas de idade (0-18, 18-30, 30-45, 45+), que podem ser mais significativos em um contexto específico.

A discretização é útil em várias situações. Por exemplo, em análises de dados demográficos, podemos discretizar a idade em faixas etárias para entender melhor os padrões demográficos. Em dados financeiros, podemos discretizar a renda em categorias de baixa, média e alta para análises de segmentação. Além disso, alguns algoritmos de mineração de dados, como árvores de decisão, exigem atributos discretos em vez de contínuos.

Normalização (Preparação de Dados)

A normalização é uma técnica de pré-processamento de dados que ajusta a escala dos atributos de um conjunto de dados, de modo que eles estejam em uma faixa comum. Essa técnica é útil quando os atributos têm escalas diferentes e é desejável que eles tenham a mesma ordem de grandeza para evitar um viés nos modelos de mineração de dados.



11225354498 - Maria Vitória Gonçalves Vieira

Existem várias abordagens para a normalização de dados, algumas das quais incluem:

Normalização min-max (escala linear): nessa abordagem, os valores de um atributo são ajustados para um intervalo específico, geralmente entre 0 e 1.

Isso é feito por meio da seguinte fórmula:

X_norm = (X - X_min) / (X_max - X_min)

Onde X_norm é o valor normalizado, X é o valor original do atributo, X_min é o valor mínimo do atributo e X_max é o valor máximo do atributo. Essa técnica mantém a relação de ordem dos dados, mas coloca todos os valores dentro do intervalo especificado.

Normalização Z-score: Nessa abordagem, os valores são transformados para terem uma média de 0 e um desvio padrão de 1. Isso é feito subtraindo a média do atributo e dividindo pelo desvio padrão.

A fórmula é a seguinte:

X_norm = (X - μ) / σ

Onde X_norm é o valor normalizado, X é o valor original do atributo, μ é a média do atributo e σ é o desvio padrão do atributo. Essa técnica torna os valores comparáveis em termos de distância em relação à média.

Normalização por decimal scaling: Nessa abordagem, os valores são ajustados dividindo-os por uma potência de 10 adequada, de modo que o valor resultante esteja dentro de uma faixa específica. Isso é útil quando se deseja manter a precisão dos dados em termos de número de dígitos significativos. Por exemplo, podemos normalizar os valores dividindo-os por 10^d, onde d é o número de dígitos necessário para colocar os valores dentro da faixa desejada.

Técnicas de Mineração de Dados

Técnicas de mineração de dados são métodos e algoritmos usados para explorar grandes conjuntos de dados, a fim de descobrir padrões, relações e informações úteis para auxiliar na tomada de decisões.

Essas técnicas são usadas em diversas áreas, como marketing, finanças, ciência, medicina, entre outras, e são uma das principais ferramentas para a análise de dados em larga escala.

11225354498 - Maria Vitória Gonçalves Vieira

Alguns exemplos de técnicas de mineração de dados incluem **associação**, **classificação**, **agrupamento (clustering)** e **mineração de texto**, entre outras. Cada técnica é aplicada de acordo com o objetivo específico da análise de dados e as características dos dados em questão.

Associação

A técnica de Associação é usada na mineração de dados para descobrir padrões frequentes em dados transacionais, ou seja, dados que registram transações de um conjunto de itens ou produtos. **O objetivo da técnica é identificar associações ou relações frequentes entre esses itens**. É também conhecida como "análise de cesta de compras", pois é frequentemente utilizada em dados de compras para identificar quais produtos tendem a ser comprados juntos.

O processo de Associação consiste em duas etapas principais: a geração de um conjunto de itens frequentes (*itemsets* frequentes) e a geração de regras de associação.

Primeira etapa: itemsets frequentes

A primeira etapa envolve a identificação de itens que aparecem com frequência em conjunto nas transações. Esses conjuntos de itens são chamados de itemsets frequentes. Por exemplo, em um conjunto de transações de compras em um supermercado, pode-se identificar que o leite e o pão são frequentemente comprados juntos, formando um itemset frequente. Já o leite e o arroz podem não ser tão frequentes, portanto, não formariam um itemset frequente.

Segunda etapa: regras de associação

Na segunda etapa, são geradas regras de associação a partir dos itemsets frequentes encontrados. Essas regras têm a forma "se X, então Y", onde X e Y são conjuntos de itens. As regras são geradas a partir dos itemsets frequentes, usando um **limiar de suporte e um limiar de confiança**.

O **suporte** é uma medida objetiva para avaliar o interesse de uma regra de associação. Representa a porcentagem de transações (%) de um banco de dados de transações onde a regra se verifica. A medida de suporte responde a seguinte questão: quão frequente a regra acontece no banco de dados?

A **confiança** é a probabilidade condicional de que Y seja comprado dado que X foi comprado. Por exemplo, se a confiança de uma regra de associação "se leite e pão, então manteiga" for

11225354498 - Maria Vitória Gonçalves Vieira

alta, isso significa que, quando um cliente compra leite e pão, é provável que ele também compre manteiga.

As regras de associação podem ser usadas em várias aplicações, como em recomendações de produtos em lojas online. Por exemplo, se um cliente compra um livro sobre culinária, as regras de associação podem ser usadas para recomendar outros livros relacionados à culinária ou itens de cozinha. Outro exemplo é em análises de dados de saúde, onde as regras de associação podem ser usadas para identificar relações entre certas doenças e fatores de risco, como hábitos alimentares ou estilo de vida.

Classificação

A técnica de classificação **é uma técnica de aprendizagem supervisionada que visa identificar a qual classe uma instância desconhecida pertence, a partir de um conjunto de instâncias previamente rotuladas**.

Em outras palavras, a partir de um conjunto de dados de treinamento com exemplos conhecidos, a técnica de classificação é capaz de criar um modelo que aprende a relação entre as características dos dados e suas classes correspondentes. Esse modelo pode ser então usado para predizer a classe de novas instâncias.

Existem diferentes algoritmos de classificação, sendo que cada um deles utiliza uma abordagem diferente para a construção do modelo. Alguns exemplos de algoritmos de classificação são: árvores de decisão, regressão logística, Naive Bayes, k-nearest neighbors (KNN), Support Vector Machines (SVM), redes neurais, entre outros.

Um exemplo de aplicação da técnica de classificação é a identificação de fraudes em cartões de crédito. Para isso, são coletados dados de transações realizadas com os cartões, como valor da transação, localização, horário, tipo de comércio, entre outros. A partir desses dados, é possível criar um modelo de classificação que aprende a relação entre as características das transações e se elas são fraudulentas ou não. Esse modelo pode então ser usado para analisar novas transações e identificar aquelas que têm alta probabilidade de serem fraudes, permitindo que ações preventivas sejam tomadas.

Algoritmo: Naive Bayes

O algoritmo Naive Bayes é um método de classificação supervisionada baseado no Teorema de Bayes. O objetivo é classificar um novo exemplo em uma das categorias predefinidas, com base na probabilidade condicional da ocorrência de cada atributo dado cada categoria.

11225354498 - Maria Vitória Gonçalves Vieira

O algoritmo assume que cada atributo é independente dos outros, o que é chamado de independência condicional. Essa é uma suposição forte e nem sempre é verdadeira, mas permite que o algoritmo seja computacionalmente eficiente e funcione bem em muitos casos.

O Naive Bayes utiliza o Teorema de Bayes para calcular a probabilidade de cada categoria dada as evidências observadas nos atributos. O Teorema de Bayes é:

$$P(C|X) = (P(X|C) * P(C)) / P(X)$$

onde P(C|X) é a probabilidade da categoria C dado o exemplo X, P(X|C) é a probabilidade de X dado C, P(C) é a probabilidade de C (antes de observar X) e P(X) é a probabilidade de X.

O algoritmo utiliza a probabilidade máxima a posteriori (MAP) para selecionar a categoria com maior probabilidade condicional dada as evidências observadas. A MAP é calculada como:

$$\text{argmax } P(C|X) = \text{argmax } P(X|C) * P(C)$$

Naive Bayes pode ser aplicado a qualquer tipo de atributo, incluindo categóricos, binários e contínuos. Para atributos contínuos, geralmente é necessário discretizá-los ou assumir uma distribuição probabilística.

Um exemplo de uso do algoritmo é na classificação de e-mails como spam ou não-spam. Nesse caso, os atributos podem ser a presença ou ausência de palavras-chave específicas, a frequência de certas palavras ou caracteres, entre outros. O Naive Bayes é capaz de aprender a partir de exemplos rotulados e classificar novos e-mails com alta precisão.

Outro exemplo é na classificação de notícias em diferentes categorias, como política, esportes, entretenimento, etc. Nesse caso, os atributos podem ser as palavras-chave encontradas no título, no corpo do texto ou em outros metadados. O Naive Bayes pode ser treinado em um conjunto de notícias rotuladas e ser usado para classificar novas notícias com base em seus atributos.

Algoritmo: k-NN

O algoritmo k-Nearest Neighbors (k-NN) é um método de classificação baseado em instâncias, ou seja, ele classifica novos pontos de dados com base em exemplos previamente rotulados, chamados de vizinhos mais próximos. Ele é um algoritmo simples e não-paramétrico, o que significa que ele não faz suposições sobre a distribuição dos dados e não tem um modelo pré-construído para ajustar aos dados.

O algoritmo opera em três etapas principais:

11225354498 - Maria Vitória Gonçalves Vieira

1. Calcular a distância: Para cada ponto de dados no conjunto de treinamento, calcula-se a distância até o novo ponto de dados. A distância pode ser calculada de várias maneiras, como a distância euclidiana ou a distância de Manhattan.

2. Encontrar os k vizinhos mais próximos: A seguir, os k pontos de dados mais próximos do novo ponto de dados são selecionados com base na distância calculada anteriormente.

3. Atribuir uma classe: Finalmente, a classe do novo ponto de dados é atribuída com base nas classes dos vizinhos mais próximos. Isso pode ser feito por meio de vários métodos, como voto majoritário ou ponderação de vizinhos mais próximos por sua proximidade.

Exemplo:

Suponha que queremos classificar frutas em duas categorias: maçãs e laranjas, com base em sua cor e diâmetro. Vamos considerar o diâmetro em centímetros e a cor em uma escala de 0 a 1, onde 0 representa vermelho para maçãs e laranja claro para laranjas, e 1 representa verde para maçãs e laranja escuro para laranjas.

Temos um conjunto de dados com as seguintes informações:

Fruta	Diâmetro (cm)	Cor
Maçã	8	0.7
Maçã	7	0.6
Laranja	9	0.8
Laranja	6	0.5

Suponha que queremos classificar uma nova fruta com diâmetro 8.5 e cor 0.75. Podemos usar o algoritmo k-NN com k = 1 para encontrar a fruta mais próxima aos valores de diâmetro e cor da nova fruta.

Para calcular a distância entre a nova fruta e as frutas existentes, podemos usar a distância euclidiana. A distância euclidiana entre a nova fruta e cada uma das frutas existentes é calculada da seguinte forma:

Distância entre a nova fruta e a primeira fruta de maçã:

$d_1 = \sqrt{((8.5-8)^2 + (0.75-0.7)^2)} = 0.85$

11225354498 - Maria Vitória Gonçalves Vieira

Distância entre a nova fruta e a segunda fruta de maçã:

d_2 = √((8.5-7)^2 + (0.75-0.6)^2) = 1.38

Distância entre a nova fruta e a primeira fruta de laranja:

d_3 = √((8.5-9)^2 + (0.75-0.8)^2) = 0.58

Distância entre a nova fruta e a segunda fruta de laranja:

d_4 = √((8.5-6)^2 + (0.75-0.5)^2) = 2.24A fruta mais próxima à nova fruta é a primeira fruta de laranja, que tem uma distância de 0,58. Portanto, classificamos a nova fruta como uma laranja.

Obs.: a notação x^y significa x elevado a y.

Agrupamento (Clusterização)

A técnica de agrupamento, também conhecida como clustering, é uma técnica de mineração de dados **não supervisionada** utilizada para identificar grupos ou clusters de objetos que compartilham características semelhantes entre si.

O objetivo do agrupamento é encontrar grupos ou segmentos de dados que são homogêneos dentro de cada grupo e heterogêneos entre os grupos. Essa técnica é útil para explorar os dados e descobrir padrões e relações desconhecidos previamente, sem a necessidade de conhecimento prévio sobre a estrutura dos dados ou sobre as classes dos objetos.

Existem diferentes algoritmos de agrupamento, cada um com suas próprias abordagens e critérios para a formação de clusters. Alguns dos algoritmos mais comuns são o k-means, hierárquico, DBSCAN e mean-shift.

Por exemplo, imagine que você possui um conjunto de dados que representa clientes de um e-commerce. Você pode aplicar a técnica de agrupamento para encontrar grupos de clientes com comportamentos de compras semelhantes. Esses grupos podem ser utilizados para personalizar campanhas de marketing, sugestões de produtos ou preços de acordo com o perfil de cada grupo.

Algoritmo: K-Means

11225354498 - Maria Vitória Gonçalves Vieira

O algoritmo K-Means é um dos algoritmos mais populares de agrupamento (clustering) em mineração de dados. Sua função é agrupar objetos em um número pré-definido de clusters (agrupamentos) de acordo com suas características, de forma que objetos semelhantes estejam no mesmo grupo e objetos diferentes estejam em grupos diferentes.

O algoritmo K-Means funciona da seguinte forma:

1. Defina o número de clusters (K) que deseja-se encontrar.

2. Selecione K pontos aleatórios do conjunto de dados como centroides iniciais.

3. Atribua cada objeto do conjunto de dados ao centróide mais próximo.

4. Calcule a média dos objetos em cada cluster e mova o centróide para a nova média.

5. Repita os passos 3 e 4 até que a configuração dos centróides não mude mais ou que um critério de parada seja atingido.

O critério de parada pode ser o número máximo de iterações do algoritmo ou quando a variação entre as posições dos centróides entre duas iterações consecutivas seja menor que um valor pré-definido.

Vejamos um exemplo prático:

Suponha que queremos agrupar um conjunto de dados de 6 objetos em 3 clusters. Inicialmente, escolhemos aleatoriamente 3 objetos como centroides iniciais. Em seguida, atribuímos cada objeto ao centróide mais próximo. Com base nessa atribuição, recalculamos as médias dos objetos em cada cluster e movemos os centróides para essas novas posições. Repetimos esse processo até que a configuração dos centróides não mude mais.

O resultado final pode ser algo como a seguinte configuração de agrupamentos:

- Cluster 1: objetos 1 e 2
- Cluster 2: objetos 3 e 4
- Cluster 3: objetos 5 e 6

O algoritmo K-Means é amplamente utilizado em diversas áreas, como marketing, biologia, ciência da computação e outras, para agrupamento de dados e análise exploratória de dados.

11225354498 - Maria Vitória Gonçalves Vieira

Mineração de Texto

Mineração de Texto é uma técnica que consiste em aplicar algoritmos e técnicas de análise de dados para **extrair informações úteis de documentos de texto**. Essa técnica é amplamente utilizada em diversas áreas, como marketing, ciências sociais, análise de sentimentos, entre outras.

O processo começa com a coleta de dados, que podem ser obtidos a partir de diversas fontes, como redes sociais, fóruns de discussão, e-mails, blogs, entre outros. Em seguida, é feita a pré-processamento dos dados, que inclui a limpeza, tokenização (separação em palavras individuais), remoção de *stop words* (veja abaixo) e outras técnicas para transformar o texto bruto em um formato que possa ser analisado pelos algoritmos.

Uma das técnicas mais comuns utilizadas na mineração de texto é a **análise de frequência de palavras**, que consiste em contar a frequência de cada palavra nos documentos e identificar as palavras mais frequentes. A partir disso, é possível identificar padrões de comportamento, tópicos mais discutidos, sentimentos expressos, entre outros insights relevantes.

Outra técnica importante é a **análise de sentimento**, que consiste em identificar a polaridade de um texto, ou seja, se ele é positivo, negativo ou neutro. Essa técnica é amplamente utilizada em empresas para monitorar a opinião dos clientes em relação a seus produtos ou serviços.

Um exemplo de aplicação da mineração de texto é a análise de feedbacks de clientes em redes sociais. Com a ajuda de algoritmos de mineração de texto, é possível identificar os principais problemas relatados pelos clientes, a polaridade dos comentários, e as palavras mais frequentes em relação a um produto ou serviço. Isso pode ajudar as empresas a tomar decisões estratégicas e melhorar a satisfação do cliente.

No contexto da Mineração de Textos, podemos fazer uso de algumas técnicas/ferramentas que ajudam no processamento de algoritmos. Dentre elas, as principais são: Thesaurus, Case Folding, remoção de Stop Words e Stemming.

Thesaurus

Thesaurus é um tipo de recurso lexical que consiste em uma lista organizada de termos relacionados entre si, em que cada termo está associado a outros termos que compartilham significado semelhante. Ele é usado para ajudar na tarefa de identificação de termos relevantes em um documento e pode ser visto como um tipo de dicionário temático.

11225354498 - Maria Vitória Gonçalves Vieira

O principal objetivo de um Thesaurus é tornar mais eficiente a identificação de termos relevantes em um texto, especialmente em casos em que o mesmo termo pode ser expresso de diferentes formas ou quando um termo pode ter diferentes significados em contextos distintos. Ele ajuda a mapear os termos relevantes em uma hierarquia organizada, permitindo assim que as técnicas de mineração de textos possam identificar de forma mais precisa e completa os termos relacionados ao assunto de interesse.

Por exemplo, imagine que estamos interessados em extrair informações relevantes sobre medicamentos em um grande conjunto de documentos médicos. Usando um Thesaurus, podemos mapear os diferentes termos que podem ser usados para se referir a medicamentos, incluindo sinônimos e termos relacionados, como "remédios", "drogas", "medicamentos prescritos", "comprimidos", "pílulas", entre outros. Isso nos permitiria identificar de forma mais precisa e completa todas as ocorrências de termos relacionados a medicamentos nos documentos de interesse.

Case Folding

Case folding é um processo comum na mineração de textos que consiste em converter todas as letras do texto em minúsculas ou maiúsculas. Essa técnica é usada para normalizar o texto, reduzindo a variação de representação do mesmo termo em diferentes lugares do texto.

Por exemplo, imagine que estamos fazendo uma análise de sentimentos de avaliações de produtos e temos a seguinte frase: "O produto é bom, mas muito CARO". Se aplicarmos o case folding, o texto ficará todo em letras minúsculas ou maiúsculas, por exemplo: "o produto é bom, mas muito caro". Isso é útil porque "caro" e "CARO" seriam tratados como termos diferentes se não fosse aplicado o case folding.

O case folding é uma técnica simples e rápida de ser aplicada, mas pode haver alguns casos em que a distinção entre letras maiúsculas e minúsculas é importante, por exemplo, em análises de nomes próprios. Nesses casos, é preciso ter cuidado ao aplicar essa técnica.

Stop Words

No contexto da mineração de textos, Stop Words são palavras consideradas irrelevantes para a análise de um documento de texto. Essas palavras geralmente são artigos, preposições, conjunções e outras palavras comuns que aparecem com frequência em um texto, mas que não contêm informações úteis para a análise de conteúdo.

A remoção de Stop Words é uma técnica comum de pré-processamento de texto utilizada para melhorar a eficiência da análise, reduzindo a quantidade de palavras a serem

11225354498 - Maria Vitória Gonçalves Vieira

consideradas e eliminando ruídos desnecessários. Por exemplo, se você estiver analisando um conjunto de documentos de notícias em inglês, as palavras "the", "and", "a", "in" e "of" são algumas das Stop Words mais comuns que provavelmente serão removidas.

No entanto, é importante notar que as Stop Words podem variar de acordo com o idioma e o contexto em que o texto está sendo analisado. Em alguns casos, palavras que são Stop Words em um idioma podem ser relevantes em outro. Por isso, é importante ter cuidado ao selecionar as palavras que serão removidas como Stop Words em um determinado projeto de mineração de texto.

Stemming

Stemming é uma técnica de pré-processamento de texto que busca reduzir as palavras a sua forma básica, eliminando suas variações morfológicas e mantendo apenas o radical. O objetivo é reduzir a dimensionalidade do vocabulário e agrupar palavras semelhantes para simplificar a análise de textos.

Por exemplo, as palavras "correr", "corrida", "corridas" e "correu" são variações morfológicas da palavra "correr". Aplicando a técnica de stemming, obtemos a palavra raiz "corr".

Existem diversas técnicas de stemming disponíveis, como o Porter Stemming Algorithm, o Snowball Stemming Algorithm e o Lancaster Stemming Algorithm, que implementam diferentes abordagens para a identificação das raízes das palavras.

No contexto da mineração de textos, a técnica de stemming é útil para lidar com a variabilidade de palavras em textos e permitir que sejam agrupados ou comparados de forma mais eficiente. No entanto, é importante lembrar que a técnica pode gerar resultados imprecisos em alguns casos, como palavras que não possuem raízes claras ou palavras que possuem sentidos diferentes dependendo do contexto.

APOSTA ESTRATÉGICA

A ideia desta seção é apresentar os pontos do conteúdo que mais possuem chances de serem cobrados em prova, considerando o histórico de questões da banca em provas de nível

11225354498 - Maria Vitória Gonçalves Vieira

semelhante à nossa, bem como as inovações no conteúdo, na legislação e nos entendimentos doutrinários e jurisprudenciais[1].

O CRISP-DM, que significa Cross-Industry Standard Process for Data Mining, é um modelo de processo de mineração de dados que oferece uma abordagem estruturada e sistemática para a realização de projetos de análise de dados. Ele é composto por seis fases principais: Entendimento do Negócio, Compreensão dos Dados, Preparação dos Dados, Modelagem, Avaliação e Entrega. Cada fase é subdividida em tarefas específicas que guiam os profissionais de dados desde o entendimento do problema até a entrega dos resultados e sua implementação no ambiente de negócios.

Uma das características mais importantes do CRISP-DM é sua flexibilidade e adaptabilidade a diferentes tipos de projetos de mineração de dados. Ele pode ser aplicado em uma ampla variedade de setores e contextos, permitindo que as equipes personalizem o processo de acordo com as necessidades específicas de cada projeto. Além disso, o modelo promove a colaboração entre diferentes áreas e profissionais, como especialistas de domínio, cientistas de dados e engenheiros de software, facilitando o desenvolvimento de soluções eficazes e orientadas pelos objetivos do negócio.

QUESTÕES ESTRATÉGICAS

Nesta seção, apresentamos e comentamos uma amostra de questões objetivas selecionadas estrategicamente: são questões com nível de dificuldade semelhante ao que você deve esperar para a sua prova e que, em conjunto, abordam os principais pontos do assunto.

A ideia, aqui, não é que você fixe o conteúdo por meio de uma bateria extensa de questões, mas que você faça uma boa revisão global do assunto a partir de, relativamente, poucas questões.

1. **(FGV / TJDFT – 2022)** Maria está explorando a seguinte tabela da base de dados de vendas do mercado HortVega:

[1] Vale deixar claro que nem sempre será possível realizar uma aposta estratégica para um determinado assunto, considerando que às vezes não é viável identificar os pontos mais prováveis de serem cobrados a partir de critérios objetivos ou minimamente razoáveis.

IDvenda	*ItensComprados*
1	Cacau, castanha, cogumelo, chia
2	Cacau, chia
3	Cacau, aveia
4	Castanha, cogumelo, tâmara

Utilizando técnicas de Mineração de Dados, Maria encontrou a seguinte informação:

Se um cliente compra Cacau, a probabilidade de ele comprar chia é de 50%. Cacau => Chia, suporte = 50% e confiança = 66,7%.

Para explorar a base de dados do HortVega, Maria utilizou a técnica de Mineração de Dados:

a) normalização;
b) classificação;
c) regra de associação;
d) clusterização;
e) redução de dimensionalidade.

Comentários:

Falou em suporte e confiança, devemos lembrar de Regras de Associação. Como uma grande quantidade de regras de associação pode ser derivada a partir de uma base de dados, mesmo que pequena, normalmente se objetiva a derivação de regras que suportem um grande número de transações e que possuam uma confiança razoável para as transações às quais elas são aplicáveis. Esses requisitos estão associados a dois conceitos centrais em mineração de regras de associação:

Suporte: o suporte, ou cobertura, de uma regra de associação é o número de transações para as quais ela faz a predição correta. Também pode ser entendida como a utilidade de uma dada regra.

Confiança: a confiança, ou acurácia, de uma regra é o número de transações que ela prediz corretamente proporcionalmente às transações para as quais ela se aplica. Também pode ser entendida como a certeza de uma dada regra.

Gabarito: C

---

2. (FGV / SEFAZ-AM – 2022) Leia o fragmento a seguir. "CRISP-DM é um modelo de referência não proprietário, neutro, documentado e disponível na Internet, sendo amplamente utilizado para descrever o ciclo de vida de projetos de Ciência de Dados. O modelo é composto por seis fases:

1. entendimento do negócio;

11225354498 - Maria Vitória Gonçalves Vieira

2. _____;
3. _____;
4. Modelagem;
5. _____ ; e
6. implantação".

Assinale a opção cujos itens completam corretamente as lacunas do fragmento acima, na ordem apresentada.

a) modelagem do negócio – limpeza de dados – testagem.
b) modelagem de requisitos – raspagem de dados – execução.
c) modelagem do negócio – mineração de dados – reexecução.
d) compreensão dos dados – preparação dos dados – avaliação.
e) mapeamento de metadados – mineração de dados – testagem.

Comentários:

Os nomes variam um pouco, mas temos que: (2) Entendimento/Compreensão de Dados; (3) Preparação dos Dados; (5) Teste e Avaliação.

Gabarito: D

---

3. (FGV / SEFAZ-AM – 2022) O tipo de aprendizado máquina, que consiste em treinar um sistema a partir de dados que não estão rotulados e/ou classificados e utilizar algoritmos que buscam descobrir padrões ocultos que agrupam as informações de acordo com semelhanças ou diferenças, é denominado:

a) dinâmico.
b) sistêmico.
c) por reforço.
d) supervisionado.
e) não supervisionado.

Comentários:

O tipo de aprendizado máquina, que consiste em treinar um sistema a partir de dados que não estão rotulados e/ou classificados é chamado de aprendizado não supervisionado. Ora, se os dados não são previamente rotulados, então o aprendizado é não supervisionado.

Gabarito: E

---

4. (FGV / SEFAZ-ES – 2021) Maria está preparando um relatório sobrea as empresas de serviços de um município, de modo a identificar e estudar o porte dessas empresas com

11225354498 - Maria Vitória Gonçalves Vieira

vistas ao estabelecimento de políticas públicas de previsões de arrecadações. Maria pretende criar nove grupos empresas, de acordo com os valores de faturamento, e recorreu às técnicas usualmente empregadas em procedimentos de data mining para estabelecer as faixas de valores de cada grupo. Assinale a opção que apresenta a técnica diretamente aplicável a esse tipo de classificação:

a) Algoritmos de associação.
b) Algoritmos de clusterização.
c) Árvores de decisão.
d) Modelagem de dados.
e) Regressão linear.

Comentários:

Ora, se ela quer criar nove grupos e empresas de acordo com os valores de faturamento e recorreu às técnicas de mineração de dados para estabelecer as faixas de valores de cada grupo significa que ela não tinha as classes previamente definidas. Logo, ela utilizou um algoritmo de aprendizado não supervisionado. No caso, trata-se claramente de algoritmos de clusterização.

Gabarito: B

---

5. (FGV / Prefeitura de Niterói – 2018) Rafael aplicou um teste de múltipla escolha de cem questões para um numeroso grupo de alunos e notou que houve uma variada distribuição de notas.

Rafael resolveu trabalhar esses dados, e agrupar esses alunos de modo que cada um ficasse no grupo mais adequado para a sua nota. Assim, poderia preparar atividades específicas para cada grupo.

Assinale a opção que indica o algoritmo mais adequado para essa tarefa.

a) Bubble sort;
b) K-means;
c) Monte Carlo.
d) Linear regression.
e) Logistic regression.

Comentários:

Vamos destacar as palavras-chave do enunciado: “grupo de alunos”, “agrupar esses alunos”, “cada um ficasse no grupo mais adequado para a sua nota”.

(a) Errado, isso é um algoritmo para ordenação de dados; (b) Correto, trata-se de algoritmo de clusterização; (c) Errado, esse é um método utilizado para estimar os possíveis

11225354498 - Maria Vitória Gonçalves Vieira

resultados de um evento incerto; (d) Errado, trata-se de um algoritmo de regressão (predição) e Rafael precisa de um algoritmo de agrupamento (descrição); (e) Errado, trata-se de um algoritmo de regressão (predição) e Rafael precisa de um algoritmo de agrupamento (descrição).

Gabarito: B

QUESTIONÁRIO DE REVISÃO E APERFEIÇOAMENTO

A ideia do questionário é elevar o nível da sua compreensão no assunto e, ao mesmo tempo, proporcionar uma outra forma de revisão de pontos importantes do conteúdo, a partir de perguntas que exigem respostas subjetivas.

São questões um pouco mais desafiadoras, porque a redação de seu enunciado não ajuda na sua resolução, como ocorre nas clássicas questões objetivas.

O objetivo é que você realize uma auto explicação mental de alguns pontos do conteúdo, para consolidar melhor o que aprendeu ;)

Além disso, as questões objetivas, em regra, abordam pontos isolados de um dado assunto. Assim, ao resolver várias questões objetivas, o candidato acaba memorizando pontos isolados do conteúdo, mas muitas vezes acaba não entendendo como esses pontos se conectam.

Assim, no questionário, buscaremos trazer também situações que ajudem você a conectar melhor os diversos pontos do conteúdo, na medida do possível.

É importante frisar que não estamos adentrando em um nível de profundidade maior que o exigido na sua prova, mas apenas permitindo que você compreenda melhor o assunto de modo a facilitar a resolução de questões objetivas típicas de concursos, ok?

Nosso compromisso é proporcionar a você uma revisão de alto nível!

Vamos ao nosso questionário:

11225354498 - Maria Vitória Gonçalves Vieira

Perguntas

1. O que é Mineração de Dados?

2. O que é Previsão na Mineração de Dados?

3. O que é Identificação na Mineração de Dados?

4. O que é Classificação na Mineração de Dados?

5. O que é Otimização na Mineração de Dados?

6. Quais são as etapas do processo de Mineração de Dados utilizando a metodologia CRISP-DM?

7. O que é a etapa de Entendimento do Negócio no CRISP-DM?

8. Qual é o objetivo da etapa de Compreensão dos Dados no CRISP-DM?

9. O que é feito na etapa de Preparação dos Dados no CRISP-DM?

10. O que acontece na etapa de Modelagem dos Dados no CRISP-DM?

11. Qual é o objetivo da etapa de Avaliação no CRISP-DM?

12. O que é a etapa de Entrega no CRISP-DM?

13. O que é incompletude de dados?

14. O que é inconsistência de dados?

15. O que é ruído de dados?

16. O que é limpeza de dados no contexto da mineração de dados?

17. O que é integração de dados no contexto da mineração de dados?

18. O que é redução de dados no contexto da mineração de dados?

19. O que é discretização e qual é a sua importância na mineração de dados?

20. O que é análise de associação em mineração de dados?

11225354498 - Maria Vitória Gonçalves Vieira

21. O que é classificação em mineração de dados?

22. O que é agrupamento em mineração de dados?

23. O que é mineração de texto em mineração de dados?

24. O que é um Thesaurus no contexto da mineração de texto?

25. O que é Case Folding no contexto da mineração de texto?

25. O que são Stop Words no contexto da mineração de texto?

27. O que é Stemming no contexto da mineração de texto?

28. O que é o algoritmo KNN (K-Nearest Neighbors)?

29. Como funciona o algoritmo K-Means?

30. O que é o classificador Naive Bayes?

31. Quais são as principais características do algoritmo KNN?

32. Em que tipo de problemas o algoritmo K-Means é comumente aplicado?

33. Qual é a principal suposição por trás do classificador Naive Bayes?

Perguntas e Respostas

1. O que é Mineração de Dados?

Resposta: A Mineração de Dados é uma área da ciência da computação que tem como objetivo extrair informações valiosas e padrões de grandes volumes de dados.

2. O que é Previsão na Mineração de Dados?

Resposta: A Previsão é uma técnica de Mineração de Dados que utiliza dados históricos para fazer estimativas ou projeções sobre eventos futuros.

3. O que é Identificação na Mineração de Dados?

11225354498 - Maria Vitória Gonçalves Vieira

Resposta: Identificação é o processo de identificar características ou propriedades de um conjunto de dados, com o objetivo de extrair informações úteis para tomada de decisões.

4. O que é Classificação na Mineração de Dados?

Resposta: Classificação é uma técnica de Mineração de Dados que consiste em separar um conjunto de dados em diferentes categorias ou classes com base em características específicas.

5. O que é Otimização na Mineração de Dados?

Resposta: Otimização é o processo de encontrar a melhor solução ou conjunto de soluções para um problema específico de acordo com critérios definidos.

6. Quais são as etapas do processo de Mineração de Dados utilizando a metodologia CRISP-DM?

Resposta: As seis etapas do processo de Mineração de Dados utilizando a metodologia CRISP-DM são: entendimento do negócio, entendimento dos dados, preparação dos dados, modelagem, avaliação e implantação.

7. O que é a etapa de Entendimento do Negócio no CRISP-DM?

Resposta: É a etapa em que se busca compreender os objetivos do projeto, os requisitos do negócio e as metas a serem alcançadas com a mineração de dados.

8. Qual é o objetivo da etapa de Compreensão dos Dados no CRISP-DM?

Resposta: O objetivo é coletar e analisar os dados disponíveis para se ter uma melhor compreensão da qualidade, relevância e disponibilidade desses dados para o projeto de mineração de dados.

9. O que é feito na etapa de Preparação dos Dados no CRISP-DM?

Resposta: Nesta etapa, os dados são limpos, transformados e integrados para que possam ser utilizados nas próximas etapas do processo de mineração de dados.

10. O que acontece na etapa de Modelagem dos Dados no CRISP-DM?

Resposta: É nessa etapa que são selecionados e aplicados os algoritmos de mineração de dados para a criação de modelos que possam ser utilizados para a análise dos dados.

11. Qual é o objetivo da etapa de Avaliação no CRISP-DM?

11225354498 - Maria Vitória Gonçalves Vieira

Resposta: O objetivo é avaliar a qualidade dos modelos criados e determinar se eles atendem aos objetivos do projeto de mineração de dados.

12. O que é a etapa de Entrega no CRISP-DM?

Resposta: É a etapa em que os resultados da mineração de dados são apresentados ao cliente ou usuário final, incluindo os relatórios finais, modelos e outras informações relevantes.

13. O que é inconsistência de dados?

Resposta: Inconsistência é um problema em que os dados possuem informações conflitantes ou contraditórias.

14. O que é ruído de dados?

Resposta: Ruído é um problema em que os dados contêm informações irrelevantes ou incorretas.

15. O que é limpeza de dados no contexto da mineração de dados?

Resposta: A limpeza de dados é um processo de pré-processamento de dados que envolve a remoção de dados inconsistentes, incompletos ou irrelevantes.

16. O que é integração de dados no contexto da mineração de dados?

Resposta: Integração de dados é o processo de combinar dados de várias fontes em um único conjunto de dados.

17. O que é transformação de dados no contexto da mineração de dados?

Resposta: Transformação de dados é o processo de alterar a estrutura ou o formato dos dados para torná-los mais adequados para análise.

18. O que é redução de dados no contexto da mineração de dados?

Resposta: Redução de dados é o processo de reduzir o tamanho ou a complexidade do conjunto de dados, preservando ao mesmo tempo suas características essenciais.

19. O que é discretização e qual é a sua importância na mineração de dados?

Resposta: Discretização é o processo de transformar variáveis contínuas em variáveis discretas, o que facilita o processo de análise de dados. A discretização é importante porque

11225354498 - Maria Vitória Gonçalves Vieira

muitos algoritmos de mineração de dados requerem dados discretos para funcionar corretamente.

20. O que é análise de associação em mineração de dados?

Resposta: A análise de associação é uma técnica de mineração de dados que busca descobrir relações entre os itens em um conjunto de dados. Essa técnica procura por padrões frequentes em um conjunto de dados e usa esses padrões para identificar associações entre os itens.

21. O que é classificação em mineração de dados?

Resposta: Classificação é uma técnica de mineração de dados que busca identificar a que classe uma determinada instância pertence com base em um conjunto de dados de treinamento. A classificação é usada em muitas aplicações, como reconhecimento de voz, reconhecimento de padrões e diagnóstico médico.

22. O que é agrupamento em mineração de dados?

Resposta: Agrupamento é uma técnica de mineração de dados que busca identificar grupos de objetos similares em um conjunto de dados. Essa técnica é usada para segmentar clientes em grupos de acordo com seu comportamento de compra, identificar fraudes em transações financeiras e em muitas outras aplicações.

23. O que é mineração de texto em mineração de dados?

Resposta: Mineração de texto é uma técnica de mineração de dados que busca extrair informações úteis de dados de texto não estruturados. Essa técnica é usada em muitas aplicações, como análise de sentimento em redes sociais, detecção de spam em e-mails e recuperação de informações em motores de busca.

24. O que é um Thesaurus no contexto da mineração de texto?

Resposta: Um Thesaurus é um conjunto de termos relacionados que podem ser usados para expandir consultas de busca de texto, encontrando palavras sinônimas ou termos relacionados.

25. O que é Case Folding no contexto da mineração de texto?

Resposta: Case Folding é a técnica de converter todas as letras do texto em minúsculas ou maiúsculas, para que o software possa reconhecer as palavras independentemente do uso de letras maiúsculas ou minúsculas.

11225354498 - Maria Vitória Gonçalves Vieira

26. O que são Stop Words no contexto da mineração de texto?

Resposta: Stop Words são palavras comuns que geralmente são ignoradas durante a mineração de texto, pois não têm significado próprio e podem ser encontradas com muita frequência em qualquer texto, como "a", "o", "de", "em", etc.

27. O que é Stemming no contexto da mineração de texto?

Resposta: Stemming é a técnica de reduzir as palavras de um texto ao seu radical ou raiz, para que palavras com a mesma raiz possam ser tratadas como iguais, independentemente das suas formas flexionadas. Por exemplo, "corrida", "correria" e "corredor" seriam todas reduzidas para a raiz "corr".

28. O que é o algoritmo KNN (K-Nearest Neighbors)?

Resposta: O algoritmo KNN é um método de aprendizado de máquina usado para classificação e regressão. Ele classifica um novo exemplo com base nas classes dos k exemplos mais próximos em um conjunto de treinamento. A classe é determinada pela maioria das classes dos k vizinhos mais próximos.

29. Como funciona o algoritmo K-Means?

Resposta: O algoritmo K-Means é um método de aprendizado de máquina não supervisionado usado para agrupar dados em clusters. Ele divide os dados em k grupos com base na similaridade entre eles. O algoritmo itera entre atribuir pontos ao cluster mais próximo e recalcular o centroide de cada cluster até que a convergência seja alcançada.

30. O que é o classificador Naive Bayes?

Resposta: O classificador Naive Bayes é um método de aprendizado de máquina probabilístico utilizado para classificação. Ele se baseia no Teorema de Bayes e na suposição de independência condicional entre os atributos. O algoritmo calcula a probabilidade de um exemplo pertencer a uma determinada classe com base nas probabilidades condicionais dos atributos.

31. Quais são as principais características do algoritmo KNN?

Resposta: O KNN é um algoritmo de aprendizado baseado em instâncias, que não requer treinamento explícito. Ele é simples de implementar e eficaz para problemas com fronteiras de decisão complexas. No entanto, ele pode ser computacionalmente caro para conjuntos de dados grandes e requer um valor adequado de k.

32. Em que tipo de problemas o algoritmo K-Means é comumente aplicado?

11225354498 - Maria Vitória Gonçalves Vieira

Resposta: O K-Means é frequentemente aplicado em problemas de agrupamento de dados, como segmentação de clientes, análise de imagens, reconhecimento de padrões e processamento de dados não rotulados. Ele é eficaz quando os dados têm características numéricas e quando o número de clusters é conhecido ou pode ser estimado.

33. Qual é a principal suposição por trás do classificador Naive Bayes?

Resposta: O classificador Naive Bayes assume independência condicional entre os atributos, o que significa que cada atributo é considerado independentemente dos outros atributos, dado o valor da classe. Embora essa suposição nem sempre seja verdadeira na prática, o classificador Naive Bayes pode fornecer resultados satisfatórios em muitos casos.

LISTA DE QUESTÕES ESTRATÉGICAS

1. **(FGV / TJDFT – 2022)** Maria está explorando a seguinte tabela da base de dados de vendas do mercado HortVega:

IDvenda	*ItensComprados*
1	Cacau, castanha, cogumelo, chia
2	Cacau, chia
3	Cacau, aveia
4	Castanha, cogumelo, tâmara

Utilizando técnicas de Mineração de Dados, Maria encontrou a seguinte informação:

Se um cliente compra Cacau, a probabilidade de ele comprar chia é de 50%. Cacau => Chia, suporte = 50% e confiança = 66,7%.

Para explorar a base de dados do HortVega, Maria utilizou a técnica de Mineração de Dados:

a) normalização;
b) classificação;
c) regra de associação;
d) clusterização;
e) redução de dimensionalidade.

2. (FGV / SEFAZ-AM – 2022) Leia o fragmento a seguir. “CRISP-DM é um modelo de referência não proprietário, neutro, documentado e disponível na Internet, sendo amplamente utilizado para descrever o ciclo de vida de projetos de Ciência de Dados. O modelo é composto por seis fases:

1. entendimento do negócio;
2. _____;
3. _____;
4. Modelagem;
5. _____ ; e
6. implantação”.

Assinale a opção cujos itens completam corretamente as lacunas do fragmento acima, na ordem apresentada.

a) modelagem do negócio – limpeza de dados – testagem.
b) modelagem de requisitos – raspagem de dados – execução.
c) modelagem do negócio – mineração de dados – reexecução.
d) compreensão dos dados – preparação dos dados – avaliação.
e) mapeamento de metadados – mineração de dados – testagem.

---

3. (FGV / SEFAZ-AM – 2022) O tipo de aprendizado máquina, que consiste em treinar um sistema a partir de dados que não estão rotulados e/ou classificados e utilizar algoritmos que buscam descobrir padrões ocultos que agrupam as informações de acordo com semelhanças ou diferenças, é denominado:

a) dinâmico.
b) sistêmico.
c) por reforço.
d) supervisionado.
e) não supervisionado.

---

4. (FGV / SEFAZ-ES – 2021) Maria está preparando um relatório sobrea as empresas de serviços de um município, de modo a identificar e estudar o porte dessas empresas com vistas ao estabelecimento de políticas públicas de previsões de arrecadações. Maria pretende criar nove grupos empresas, de acordo com os valores de faturamento, e recorreu às técnicas usualmente empregadas em procedimentos de data mining para estabelecer as

11225354498 - Maria Vitória Gonçalves Vieira

faixas de valores de cada grupo. Assinale a opção que apresenta a técnica diretamente aplicável a esse tipo de classificação:

a) Algoritmos de associação.
b) Algoritmos de clusterização.
c) Árvores de decisão.
d) Modelagem de dados.
e) Regressão linear.

---

5. (FGV / Prefeitura de Niterói – 2018) Rafael aplicou um teste de múltipla escolha de cem questões para um numeroso grupo de alunos e notou que houve uma variada distribuição de notas.

Rafael resolveu trabalhar esses dados, e agrupar esses alunos de modo que cada um ficasse no grupo mais adequado para a sua nota. Assim, poderia preparar atividades específicas para cada grupo.

Assinale a opção que indica o algoritmo mais adequado para essa tarefa.

a) Bubble sort;
b) K-means;
c) Monte Carlo.
d) Linear regression.
e) Logistic regression.

Gabaritos

1. C

2. D

3. E

4. B

5. B

11225354498 - Maria Vitória Gonçalves Vieira

11225354498 - Maria Vitória Gonçalves Vieira

Questões Adicionais

As questões apresentadas a seguir integram o Banco de Questões do Passo Estratégico. Recomenda-se utilizá-las como um recurso complementar para a prática e consolidação dos conhecimentos adquiridos no material teórico, de acordo com o estilo adotado pela banca organizadora.

Bom estudo!

1. O que são Stem Words no processo de mineração de textos?

A) Palavras reduzidas a sua raiz, permitindo agrupar diferentes formas da mesma palavra.
B) Palavras que são removidas durante o pré-processamento por serem muito frequentes.
C) Palavras que são adicionadas a um texto para melhorar sua legibilidade.
D) Palavras que indicam a estrutura gramatical de uma frase.
E) Palavras usadas em processos de agrupamento de documentos.

2. Qual técnica de pré-processamento de dados ajusta os valores dos atributos para uma escala comum, facilitando a comparação entre diferentes atributos?

A) Discretização
B) Transformação
C) Integração
D) Normalização
E) Limpeza de Dados

3. Qual das opções a seguir NÃO faz parte dos processos de pré-processamento de dados?

A) Limpeza de dados, para corrigir erros e inconsistências.
B) Transformação de dados, para consolidar dados de várias fontes e formatos.
C) Redução de dados, para minimizar o volume de dados a serem analisados.
D) Discretização de dados, para simplificar grandes quantidades de dados contínuos.
E) Criação de hipóteses para testar predições sobre os dados.

4. No âmbito da mineração de texto, qual técnica específica é utilizada para converter todas as letras de um texto para minúsculas, garantindo a consistência na análise, independentemente da capitalização original das palavras?

A) Tokenização
B) Stop Words
C) Stemming
D) Case Folding
E) Lematização

5. Considerando o modelo CRISP-DM utilizado para estruturar projetos de mineração de dados, qual das seguintes fases é responsável por definir claramente os objetivos do projeto e entender

11225354498 - Maria Vitória Gonçalves Vieira

as necessidades e restrições do negócio para garantir que o projeto de mineração de dados esteja alinhado com os objetivos estratégicos da organização?

A) Entendimento do Negócio
B) Compreensão dos Dados
C) Preparação dos Dados
D) Modelagem
E) Avaliação

6. Identifique o padrão correto para a sequência de técnicas de pré-processamento de dados: Coleta de Dados → _____ → Discretização → _____ → Preparação para Modelagem.

A) Limpeza de Dados; Integração de Dados
B) Integração de Dados; Transformação
C) Normalização; Redução de Dimensionalidade
D) Limpeza de Dados; Normalização
E) Redução de Dimensionalidade; Integração de Dados

7. O que são Stop Words no contexto da mineração de textos?

A) Palavras-chave que devem ser destacadas em um texto.
B) Palavras que são removidas durante o pré-processamento por serem muito frequentes.
C) Palavras que são adicionadas a um texto para melhorar sua legibilidade.
D) Palavras que indicam a estrutura gramatical de uma frase.
E) Palavras usadas em processos de agrupamento de documentos.

8. Preencha as lacunas na frase a seguir: No processo de mineração de dados, a técnica de _____ é utilizada para ajustar os valores dos atributos para uma escala comum, enquanto a técnica de _____ é usada para transformar variáveis contínuas em categorias discretas.

A) discretização; normalização
B) normalização; discretização
C) integração; limpeza de dados
D) discretização; transformação
E) normalização; transformação

9. Qual algoritmo de aprendizado de máquina é utilizado para classificar dados com base na distância entre pontos de dados e os seus vizinhos mais próximos?

A) K-Means
B) Regressão Linear
C) k-Nearest Neighbors (k-NN)
D) Naive Bayes
E) Árvores de Decisão

10. Qual é o objetivo principal da técnica de normalização no pré-processamento de dados?

11225354498 - Maria Vitória Gonçalves Vieira

A) Remover valores ausentes
B) Transformar dados categóricos em numéricos
C) Identificar outliers
D) Dividir os dados em intervalos iguais
E) Ajustar os valores dos atributos para uma escala comum

GABARITOS E COMENTÁRIOS

1. O que são Stem Words no processo de mineração de textos?

A) Palavras reduzidas a sua raiz, permitindo agrupar diferentes formas da mesma palavra.
B) Palavras que são removidas durante o pré-processamento por serem muito frequentes.
C) Palavras que são adicionadas a um texto para melhorar sua legibilidade.
D) Palavras que indicam a estrutura gramatical de uma frase.
E) Palavras usadas em processos de agrupamento de documentos.

Gabarito: A

Comentários: Stemming é uma importante etapa de pré-processamento em técnicas de mineração de textos e NLP. Consiste em reduzir as palavras a sua raiz ou raiz comum, permitindo assim agrupar diferentes formas da mesma palavra. Por exemplo, as palavras 'correr', 'corre' e 'corrido' podem ser reduzidas à raiz 'corr'. Este processo ajuda a evitar a multiplicidade de formas da mesma palavra, facilitando os processos de pesquisa, análise e comparação.

2. Qual técnica de pré-processamento de dados ajusta os valores dos atributos para uma escala comum, facilitando a comparação entre diferentes atributos?

A) Discretização
B) Transformação
C) Integração
D) Normalização
E) Limpeza de Dados

Gabarito: D

Comentários: A normalização ajusta os valores dos atributos para uma escala comum, tornando-os comparáveis e facilitando a análise.

3. Qual das opções a seguir NÃO faz parte dos processos de pré-processamento de dados?

A) Limpeza de dados, para corrigir erros e inconsistências.
B) Transformação de dados, para consolidar dados de várias fontes e formatos.
C) Redução de dados, para minimizar o volume de dados a serem analisados.

11225354498 - Maria Vitória Gonçalves Vieira

D) Discretização de dados, para simplificar grandes quantidades de dados contínuos.
E) Criação de hipóteses para testar predições sobre os dados.

Gabarito: E

Comentários: A criação de hipóteses para testar predições sobre os dados é um processo que ocorre após o pré-processamento de dados, durante a fase de modelagem e análise de dados. Assim, a alternativa E é a única que não faz parte dos processos de pré-processamento de dados.

4. No âmbito da mineração de texto, qual técnica específica é utilizada para converter todas as letras de um texto para minúsculas, garantindo a consistência na análise, independentemente da capitalização original das palavras?

A) Tokenização
B) Stop Words
C) Stemming
D) Case Folding
E) Lematização

Gabarito: D

Comentários: A técnica de Case Folding é utilizada para converter todas as letras de um texto para minúsculas, garantindo a consistência na análise.

5. Considerando o modelo CRISP-DM utilizado para estruturar projetos de mineração de dados, qual das seguintes fases é responsável por definir claramente os objetivos do projeto e entender as necessidades e restrições do negócio para garantir que o projeto de mineração de dados esteja alinhado com os objetivos estratégicos da organização?

A) Entendimento do Negócio
B) Compreensão dos Dados
C) Preparação dos Dados
D) Modelagem
E) Avaliação

Gabarito: A

Comentários: A fase de Entendimento do Negócio é crucial para garantir que os objetivos do projeto de mineração de dados estejam alinhados com os objetivos estratégicos da organização e para definir claramente as necessidades e restrições do negócio.

6. Identifique o padrão correto para a sequência de técnicas de pré-processamento de dados: Coleta de Dados → _____ → Discretização → _____ → Preparação para Modelagem.

A) Limpeza de Dados; Integração de Dados
B) Integração de Dados; Transformação
C) Normalização; Redução de Dimensionalidade

11225354498 - Maria Vitória Gonçalves Vieira

D) Limpeza de Dados; Normalização
E) Redução de Dimensionalidade; Integração de Dados

Gabarito: D

Comentários: A sequência correta de pré-processamento de dados envolve a Limpeza de Dados seguida pela Normalização, antes da discretização e preparação final para a modelagem.

7. O que são Stop Words no contexto da mineração de textos?

A) Palavras-chave que devem ser destacadas em um texto.
B) Palavras que são removidas durante o pré-processamento por serem muito frequentes.
C) Palavras que são adicionadas a um texto para melhorar sua legibilidade.
D) Palavras que indicam a estrutura gramatical de uma frase.
E) Palavras usadas em processos de agrupamento de documentos.

Gabarito: B

Comentários: Stop Words são palavras muito frequentes em um texto que são removidas durante o pré-processamento, pois geralmente não contribuem para a análise ou compreensão do conteúdo.

8. Preencha as lacunas na frase a seguir: No processo de mineração de dados, a técnica de _____ é utilizada para ajustar os valores dos atributos para uma escala comum, enquanto a técnica de _____ é usada para transformar variáveis contínuas em categorias discretas.

A) discretização; normalização
B) normalização; discretização
C) integração; limpeza de dados
D) discretização; transformação
E) normalização; transformação

Gabarito: B

Comentários: A normalização é utilizada para ajustar os valores dos atributos para uma escala comum, e a discretização transforma variáveis contínuas em categorias discretas.

9. Qual algoritmo de aprendizado de máquina é utilizado para classificar dados com base na distância entre pontos de dados e os seus vizinhos mais próximos?

A) K-Means
B) Regressão Linear
C) k-Nearest Neighbors (k-NN)
D) Naive Bayes
E) Árvores de Decisão

Gabarito: C

11225354498 - Maria Vitória Gonçalves Vieira

Comentários: O algoritmo k-Nearest Neighbors (k-NN) classifica dados com base na distância entre pontos de dados e seus vizinhos mais próximos.

10. Qual é o objetivo principal da técnica de normalização no pré-processamento de dados?

A) Remover valores ausentes
B) Transformar dados categóricos em numéricos
C) Identificar outliers
D) Dividir os dados em intervalos iguais
E) Ajustar os valores dos atributos para uma escala comum

Gabarito: E

Comentários: A normalização é utilizada para ajustar os valores dos atributos para uma escala comum, facilitando a comparação e a análise de dados.

1.A	2.D	3.E	4.D	5.A
6.D	7.B	8.B	9.C	10.E

11225354498 - Maria Vitória Gonçalves Vieira

ESSA LEI TODO MUNDO CONHECE:
PIRATARIA É CRIME.

Mas é sempre bom revisar o porquê e como você pode ser prejudicado com essa prática.

1. 

Professor investe seu tempo para elaborar os cursos e o site os coloca à venda.

2. 

Pirata divulga ilicitamente (grupos de rateio), utilizando-se do anonimato, nomes falsos ou laranjas (geralmente o pirata se anuncia como formador de "grupos solidários" de rateio que não visam lucro).

3. 

Pirata cria alunos fake praticando falsidade ideológica, comprando cursos do site em nome de pessoas aleatórias (usando nome, CPF, endereço e telefone de terceiros sem autorização).

4. 

Pirata compra, muitas vezes, clonando cartões de crédito (por vezes o sistema anti-fraude não consegue identificar o golpe a tempo).

5. 

Pirata fere os Termos de Uso, adultera as aulas e retira a identificação dos arquivos PDF (justamente porque a atividade é ilegal e ele não quer que seus fakes sejam identificados).

6. 

Pirata revende as aulas protegidas por direitos autorais, praticando concorrência desleal e em flagrante desrespeito à Lei de Direitos Autorais (Lei 9.610/98).

7. 

Concurseiro(a) desinformado participa de rateio, achando que nada disso está acontecendo e esperando se tornar servidor público para exigir o cumprimento das leis.

8. 

O professor que elaborou o curso não ganha nada, o site não recebe nada, e a pessoa que praticou todos os ilícitos anteriores (pirata) fica com o lucro.



Deixando de lado esse mar de sujeira, aproveitamos para agradecer a todos que adquirem os cursos honestamente e permitem que o site continue existindo.