Estratégia Concursos

Aula 09

DataPrev (Analista de TI - Desenvolvimento de Software) Passo Estratégico de Conhecimentos Específicos - 2024 (Pós-Edital)

Autor:

09 de Setembro de 2024

11225354498 - Maria Vitória Gonçalves Vieira

ETL - Extração, Transformação e Carga

Sumário

Conteúdo 1

Glossário de termos 3

Roteiro de revisão 4

ETL - Extração, Transformação e Carga 4

Componente de Extração 5

Componente de Limpeza e Conformidade 7

Componente de Entrega 8

Componente de Gestão 10

Processo de ETL 12

Apêndice: Funções e Técnicas Relacionadas 14

Aposta estratégica 15

Questões Estratégicas 16

Questionário de revisão e aperfeiçoamento 21

Perguntas 22

Perguntas e Respostas 22

Lista de Questões Estratégicas 25

Conteúdo

ETL. Extração. Transformação. Carga. Características. Componentes de ETL. Processo de ETL.

11225354498 - Maria Vitória Gonçalves Vieira

ANÁLISE ESTATÍSTICA

Inicialmente, convém destacar o percentual de incidência do assunto, dentro da disciplina **Banco de Dados e Business Intelligence** em concursos/cargos similares. Quanto maior o percentual de cobrança de um dado assunto, maior sua importância.

Obs.: *um mesmo assunto pode ser classificado em mais de um tópico devido à multidisciplinaridade de conteúdo*.

Assunto	Relevância na disciplina em concursos similares
SQL	**21.6 %**
BI (Business Intelligence)	**9.0 %**
DW - Data Warehouse	**7.2 %**
SQL Server	**7.2 %**
Oracle	**6.3 %**
Banco de Dados Multidimensionais	**5.4 %**
Data Mining	**5.4 %**
Administração de banco de dados	**3.6 %**
Banco de Dados	**2.7 %**
Formas normais	**2.7 %**
ETL (Extract Transform Load)	**2.7 %**
Banco de Dados Relacionais	**2.7 %**
Arquitetura de Banco de Dados	**1.8 %**
SGBD - Sistema de Gerenciamento de Banco de Dados	**1.8 %**
OLAP (On-line Analytical Processing)	**1.8 %**
Segurança	**1.8 %**
MS-Access	**1.8 %**
Modelo relacional	**1.8 %**
Metadados e Metainformação	**1.8 %**
Álgebra relacional	**0.9 %**
Banco de Dados Paralelos e Distribuídos	**0.9 %**
Gerência de Transações	**0.9 %**
Modelagem de dados	**0.9 %**
Gatilhos (Triggers)	**0.9 %**
DER - Diagrama de Entidade e Relacionamento	**0.9 %**
Visão (View)	**0.9 %**
Banco de Dados Textuais	**0.9 %**
Índices	**0.9 %**
PostgreSQL	**0.9 %**
MySQL	**0.9 %**
Big Data	**0.9 %**

11225354498 - Maria Vitória Gonçalves Vieira

GLOSSÁRIO DE TERMOS

Faremos uma lista de termos que são relevantes ao entendimento do assunto desta aula. Caso tenha alguma dúvida durante a leitura, esta seção pode lhe ajudar a esclarecer.

ETL: refere-se a Extração, Transformação e Carga, que é um processo de integração de dados usado para mover dados de várias fontes, transformá-los em um formato comum e carregá-los em um destino de destino.

Componente de Extração: processo de recuperar dados de várias fontes, como bancos de dados, planilhas, documentos ou aplicativos de terceiros, e transferi-los para um local centralizado para processamento adicional.

Componente de Limpeza e Conformidade: concentra-se em limpar e transformar os dados em um formato consistente e padronizado para garantir que os dados sejam precisos e confiáveis.

Componente de Entrega: etapa final do processo de ETL em que os dados transformados e limpos são carregados em um destino, como um data warehouse, banco de dados ou aplicativo.

Componente de Gestão: refere-se às tarefas de gerenciamento, como agendamento de tarefas, monitoramento do desempenho do sistema, gerenciamento de erros e solução de problemas.

Processo de ETL: refere-se ao conjunto de etapas necessárias para extrair, transformar e carregar dados de várias fontes para um destino final.

Data Mapping: envolve a identificação de como os dados de uma fonte devem ser transformados para corresponder aos requisitos de destino, como formato e estrutura de dados.

Scripts ETL: são códigos escritos para executar as tarefas específicas do processo de ETL, como extração de dados de uma fonte, transformação de dados e carregamento de dados em um destino.

ELT: é a sigla de Extrair, Carregar e Transformar, que é uma abordagem alternativa ao processo tradicional de ETL, em que a transformação de dados é realizada no local de destino, em vez de ser realizada no processo de ETL.

Data Quality: refere-se à precisão, consistência e integridade dos dados. A qualidade dos dados pode ser melhorada por meio de técnicas de limpeza e conformidade de dados.

Processamento em lote: execução de tarefas em um conjunto de dados completo em vez de executá-las em tempo real ou sob demanda.

11225354498 - Maria Vitória Gonçalves Vieira

Master Data Management (MDM): MDM refere-se a um conjunto de práticas, tecnologias e processos usados para gerenciar dados críticos de negócios, como informações de clientes, fornecedores e produtos.

Data virtualization: abordagem de integração de dados que permite que os usuários acessem e consultem dados de várias fontes sem a necessidade de copiar os dados para um data warehouse ou outro destino centralizado.

Event stream processing and ETL: são abordagens para processar fluxos de eventos em tempo real para extrair, transformar e carregar dados em um destino final.

ROTEIRO DE REVISÃO

A ideia desta seção é apresentar um roteiro para que você realize uma revisão completa do assunto e, ao mesmo tempo, destacar aspectos do conteúdo que merecem atenção.

ETL - Extração, Transformação e Carga

ETL -"**Extração, Transformação e Carga**" (*Extract*, *Transform* e *Load*, em inglês) - é um processo utilizado em projetos de integração de dados. A motivação para o uso do ETL é a necessidade de mover dados de diferentes fontes, com diferentes formatos e estruturas, para um local centralizado e consistente, a fim de que esses dados possam ser utilizados para análises e tomadas de decisão.

A importância do ETL está diretamente relacionada à necessidade de integrar dados de fontes diversas, como bancos de dados, arquivos, sistemas de terceiros, entre outros, em um único repositório de dados, a fim de obter informações relevantes para o negócio. O processo permite a transformação dos dados de forma consistente, garantindo que eles sejam padronizados e compatíveis com o modelo de dados do sistema de destino.

Uma etapa importante do ETL é a limpeza dos dados, garantindo que informações erradas, incompletas ou duplicadas sejam tratadas antes da carga. Isso ajuda a melhorar a qualidade dos dados e, consequentemente, a tomada de decisão com base nesses dados.

Componentes de ETL

O processo de ETL tem quatro componentes principais: **extração, limpeza e conformidade, entrega e gestão**. Cada uma dessas etapas é dividida em subsistemas conforme descrito a seguir. Um subsistema pode ser visto como uma parte do processo ou das ações necessárias para cumprir as tarefas de cada componente. Assim temos:

11225354498 - Maria Vitória Gonçalves Vieira

1. **Extração**. Coleta de dados brutos a partir dos sistemas de origem e, geralmente, gravação em disco no ambiente de ETL antes de qualquer reestruturação significativa dos dados. Subsistemas de 1 a 3 apoiam o processo de extração. (3 subsistemas)

2. **Limpeza e conformidade**. Concentra-se em limpar e transformar os dados em um formato consistente e padronizado para garantir que os dados sejam precisos e confiáveis. Subsistemas de 4 a 8 descrevem a arquitetura necessária para suportar os processos de limpeza e conformidade (5)

3. **Entrega**. Etapa em que os dados transformados e limpos são carregados em um destino, como um data warehouse, banco de dados ou aplicativo. Subsistemas de 9 a 21 fornecem a capacidade de entregar os dados ao servidor de apresentação. (13)

4. **Gestão**. Refere-se às tarefas de gerenciamento, como agendamento de tarefas, monitoramento do desempenho do sistema, gerenciamento de erros e solução de problemas. Subsistemas de 22 a 34 descrevem os componentes necessários para apoiar o gerenciamento contínuo do sistema de ETL. (13)

Componente de Extração

Este é o primeiro componente do ETL, e consiste em obter dados de uma ou mais fontes externas e transferi-los para o ambiente do ETL para posterior transformação e carga em um local centralizado.

Para realizar a extração, podem ser utilizadas diversas técnicas, tais como:

- **Extração de dados de bancos de dados**: extração de dados diretamente de bancos de dados, utilizando comandos SQL para selecionar as informações desejadas. É possível extrair dados de bancos de dados relacionais, como MySQL, PostgreSQL e SQL Server, e também de bancos de dados NoSQL, como MongoDB e Cassandra.
- **Extração de dados de arquivos**: extração de dados de arquivos no formato CSV, XML, JSON, entre outros. É necessário utilizar ferramentas ou bibliotecas para realizar a leitura e extração dos dados dos arquivos.
- **Extração de dados de APIs**: extração de dados de APIs (Application Programming Interface), utilizando requisições HTTP para obter informações em formato JSON ou XML.

O processo de extração abre várias possibilidades, como :

- Possibilidade de integrar dados de diferentes fontes em um único repositório, facilitando a análise e tomada de decisão com base nesses dados.
- Possibilidade de limpeza e tratamento dos dados antes da carga, melhorando a qualidade dos dados e evitando problemas de duplicação ou inconsistência.
- Automatização do processo de extração, o que reduz o tempo e os custos envolvidos na integração de dados.

11225354498 - Maria Vitória Gonçalves Vieira

- Possibilidade de realizar a extração de dados em tempo real, permitindo que os dados estejam sempre atualizados e disponíveis para análise e tomada de decisão.

Subsistemas da Extração

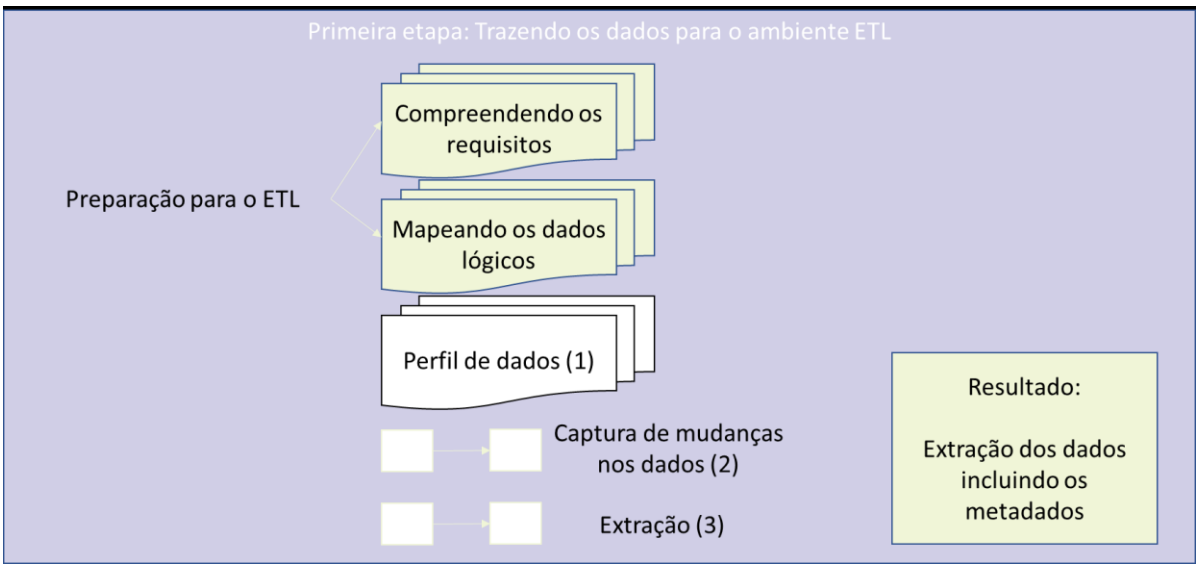
Os três subsistemas da extração em um processo ETL são o Data Profiling, a Captura de Alterações nos Dados e o Sistema de Extração.

1. **Data Profiling (Perfil de Dados):** é um processo que consiste em analisar os dados de origem para identificar problemas como duplicação, inconsistências, valores nulos ou fora do formato esperado. Dessa forma, é possível identificar problemas nos dados antes da extração, para que esses problemas possam ser tratados antes da carga. Por exemplo, pode-se identificar que há campos vazios ou que há campos com formatos diferentes daqueles esperados, como datas em formatos diferentes ou valores com diferentes unidades de medida.

2. **Captura de Alterações nos Dados:** tem como objetivo identificar quaisquer alterações que ocorreram nos dados de origem desde a última extração. Isso é importante para garantir que apenas os dados atualizados e relevantes sejam extraídos, reduzindo o tempo e os custos envolvidos no processo. Existem diferentes técnicas para capturar alterações nos dados, como o uso de campos de data e hora ou o registro de mudanças em log.

3. **Sistema de Extração:** é o processo responsável por coletar os dados de origem identificados pelo Data Profiling e pela Captura de Alterações nos Dados. Esse processo pode envolver a utilização de diferentes ferramentas e técnicas, como consultas SQL, scripts de extração personalizados ou ferramentas ETL especializadas.

Os três subsistemas podem ser vistos na figura abaixo:



11225354498 - Maria Vitória Gonçalves Vieira

Componente de Limpeza e Conformidade

O componente de limpeza e conformidade de dados é uma parte crítica do processo de transformação no ETL. Esse componente é responsável **por garantir que os dados extraídos estejam limpos, completos e conformes**, para que possam ser utilizados de maneira eficaz nas análises e nos processos de tomada de decisão.

Com isso, é possível identificar e corrigir quaisquer erros, inconsistências e duplicidades nos dados extraídos. Isso pode incluir a remoção de caracteres especiais, a correção de valores incorretos ou a normalização de valores em diferentes formatos. A limpeza pode ser realizada manualmente ou através de ferramentas de limpeza de dados automatizadas.

Subsistemas da Limpeza e Conformidade

Os cinco subsistemas da limpeza e conformidade de dados são o Sistema de Limpeza de Dados, Esquema de Eventos de Erro, Dimensão de Auditoria, Sistema de Deduplicação e Sistema de Conformidade. Esses subsistemas trabalham em conjunto para garantir que os dados extraídos estejam limpos, completos e conformes.

Vejamos:

4. **Sistema de Limpeza de Dados** é responsável por identificar e corrigir dados "sujos". Isso pode incluir a remoção de caracteres especiais, a correção de valores incorretos ou a normalização de valores em diferentes formatos.

5. **Esquema de Eventos de Erro** é responsável por registrar e rastrear quaisquer erros que ocorram durante o processo de limpeza e conformidade de dados. O esquema deve conter informações sobre o erro, sua causa, a data e hora em que ocorreu, bem como a ação corretiva tomada. Essas informações podem ser usadas para análise e para melhorar o processo.

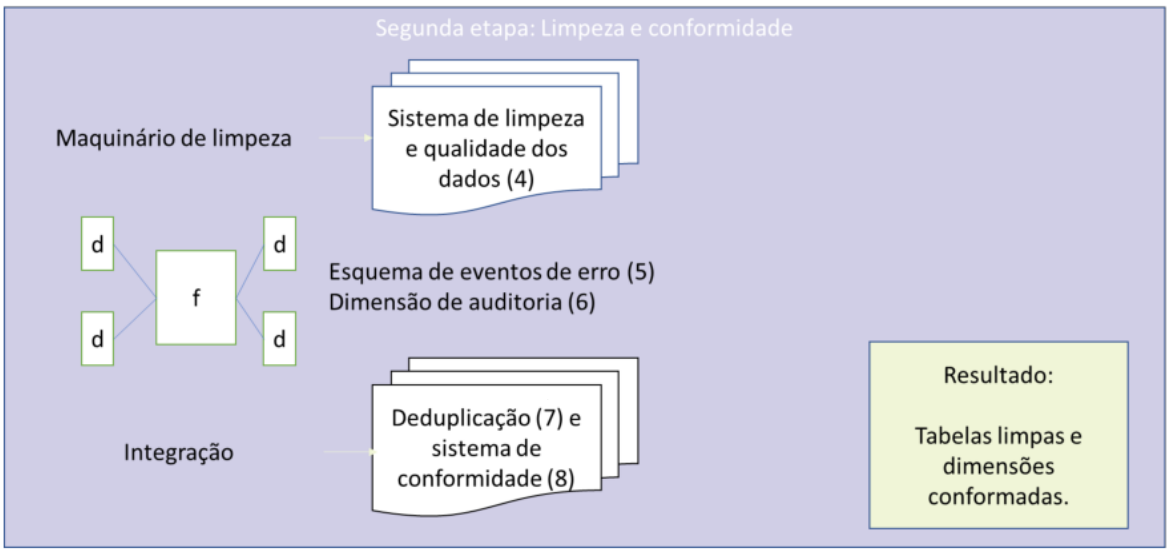
6. **Dimensão de Auditoria** rastreia as mudanças nos dados ao longo do tempo e fornecer uma trilha de auditoria detalhada. A dimensão de auditoria deve incluir informações sobre quem fez a mudança, quando a mudança foi feita e qual foi a mudança. Isso ajuda a garantir a integridade dos dados e a conformidade com regulamentações e normas.

7. **Sistema de Deduplicação** identifica e remove quaisquer dados duplicados nos dados extraídos. Assegura que os dados sejam precisos e evita resultados de análise incorretos ou decisões de negócios equivocadas.

8. **Sistema de Conformidade** responsável por garantir que os dados extraídos estejam em conformidade com as regras de negócios e requisitos regulatórios aplicáveis. Isso pode incluir a validação de campos obrigatórios, a conformidade com regras de formatação ou a verificação de dados duplicados.

11225354498 - Maria Vitória Gonçalves Vieira

Os cinco subsistemas podem ser vistos na figura abaixo:



Componente de Entrega

O componente de entrega é a etapa do processo ETL onde os dados limpos e transformados são efetivamente carregados em um data warehouse, data lake ou em outra plataforma de armazenamento e análise de dados.

A entrega pode ser realizada por meio de vários métodos, incluindo carga completa (onde todos os dados são carregados de uma só vez), carga incremental (onde apenas as atualizações e novos dados são carregados) ou carga por lote (onde um conjunto de dados é carregado de uma só vez).

Subsistemas da Entrega

O componente de entrega possui vários subsistemas. Vamos relembrar cada um deles.

9. **Gerenciador da alteração lenta da dimensão (SCD - slowly changing dimension):** gerencia as dimensões que sofrem alterações ao longo do tempo, como uma mudança no endereço de um cliente, por exemplo. O SCD é responsável por manter o histórico dessas alterações, permitindo que os dados sejam analisados ao longo do tempo.

10. **Gerador de chave substituta**: responsável por gerar uma chave substituta única para cada registro que é carregado na plataforma de destino. A chave substituta é usada para identificar exclusivamente cada registro na plataforma e é importante quando os dados não têm uma chave natural única.

11. **Gerenciador de hierarquia**: gerencia as hierarquias de dados, como uma hierarquia de produtos em uma loja online. Ele garante que as hierarquias sejam mantidas corretamente e possam ser usadas para análise de dados.

12. **Gerenciador de dimensões especiais**: gerencia dimensões especiais que não seguem a estrutura tradicional de dimensões em um modelo dimensional, como dimensões de tempo, dimensões de lixo (Junk), mini-dimensões, dimensões reduzidas (Shrunken Subset) e dimensões estáticas (Small Static Dimensions).

13. **Construtores da tabela fato**: constrói a tabela fato que contém as métricas e medidas que são analisadas na plataforma de destino. Ele combina os dados das tabelas de dimensões com as informações das tabelas de fatos, criando uma tabela que contém dados analisáveis.

14. **Pipeline da chave substituta**: cria uma linha de tempo da chave substituta gerada pelo Gerador de chave substituta, permitindo que os dados sejam rastreados ao longo do tempo.

15. **Construção da tabela ponte para dimensões multivaloradas**: responsável pela construção de tabelas de ponte para dimensões multivaloradas, permitindo que múltiplos valores sejam associados a uma única chave de dimensão.

16. **Gerenciador de dados atrasados**: gerencia a carga de dados atrasados, permitindo que dados históricos sejam carregados para análise na plataforma de destino.

17. **Sistema de gerenciamento das dimensões**: gerencia as dimensões em uma plataforma de destino, garantindo que elas sejam atualizadas corretamente.

18. **Sistema provedor dos fatos**: fornece as informações de fatos na plataforma de destino, garantindo que as métricas e medidas possam ser analisadas.

19. **Construção das tabelas agregadas**: constrói tabelas agregadas que contêm dados resumidos para acelerar as consultas e análises na plataforma de destino.

20. **Construção do cubo OLAP**: Um cubo OLAP (Online Analytical Processing) é uma estrutura multidimensional que permite uma análise mais rápida e flexível dos dados armazenados no data warehouse. Ele permite que os usuários façam consultas mais complexas e obtenham resultados de forma mais eficiente, agregando e sumarizando os dados de diferentes dimensões. O processo de construção do cubo OLAP envolve a definição das dimensões e medidas, a criação das hierarquias, a configuração dos níveis de agregação, a modelagem dos relacionamentos entre as tabelas e a definição de cálculos e medidas personalizadas

21. **Gerenciamento da propagação de dados**: Depois que os dados são carregados no data warehouse e transformados de acordo com as regras de negócio definidas, eles precisam ser propagados para os usuários finais, relatórios e outras aplicações que acessam o data warehouse. O processo de propagação envolve a criação de interfaces de consulta para que os usuários possam extrair informações do data warehouse e a disponibilização desses dados em tempo real ou em intervalos regulares

11225354498 - Maria Vitória Gonçalves Vieira

Componente de Gestão

O componente de Gestão é responsável por gerenciar todo o processo de ETL, desde o agendamento das tarefas até a monitoração do desempenho do sistema. Ele é composto por vários subsistemas, que trabalham juntos para garantir que o processo de ETL seja executado de forma confiável e eficiente.

Vejamos seus subsistemas.

Subsistemas de Gestão

22. **Agendador de Jobs**: responsável por programar a execução dos jobs ETL de acordo com uma agenda predefinida. Ele permite que as tarefas sejam executadas em horários específicos e em intervalos regulares.

23. **Sistema de backup**: responsável por garantir que todos os dados e metadados do ETL sejam protegidos e possam ser recuperados em caso de falhas ou desastres. Isso envolve a criação de backups regulares dos dados do ETL e dos metadados do processo de ETL.

24. **Sistema de recuperação e restart**: garante que o processo de ETL possa ser reiniciado em caso de falhas. Isso envolve a capacidade de recuperar dados de uma execução anterior do ETL e reiniciar o processo de onde ele parou.

25. **Sistema de controle de versão**: gerencia as diferentes versões do código-fonte do ETL, permitindo que a equipe trabalhe em paralelo em diferentes recursos ou funcionalidades, evitando conflitos no código.

26. **Sistema de migração de versão**: permite que as versões do ETL possam ser atualizadas sem interrupção do fluxo de dados. Isso envolve a capacidade de migrar dados de uma versão anterior do ETL para uma versão atualizada.

27. **Monitor de Workflow**: monitora o progresso do fluxo de trabalho do ETL, alertando a equipe em caso de falhas ou atrasos. Ele permite que a equipe monitore a execução do ETL em tempo real e tome medidas proativas para lidar com problemas.

28. **Sistema de ordenação**: garante que os dados sejam processados em uma ordem específica, se necessário. Isso é importante em situações em que os dados devem ser processados em uma ordem específica para garantir a integridade e a consistência dos resultados.

29. **Analisador de ancestrais e dependência**: responsável por analisar as dependências entre diferentes componentes do ETL e seus ancestrais. Isso permite que a equipe entenda

11225354498 - Maria Vitória Gonçalves Vieira

as interações complexas entre diferentes componentes do ETL e tome medidas proativas para evitar problemas.

30. **Sistemas para problemas de escala**: garante que o ETL possa lidar com grandes volumes de dados. Isso envolve a capacidade de escalar horizontalmente o ETL, adicionando mais recursos, conforme necessário.

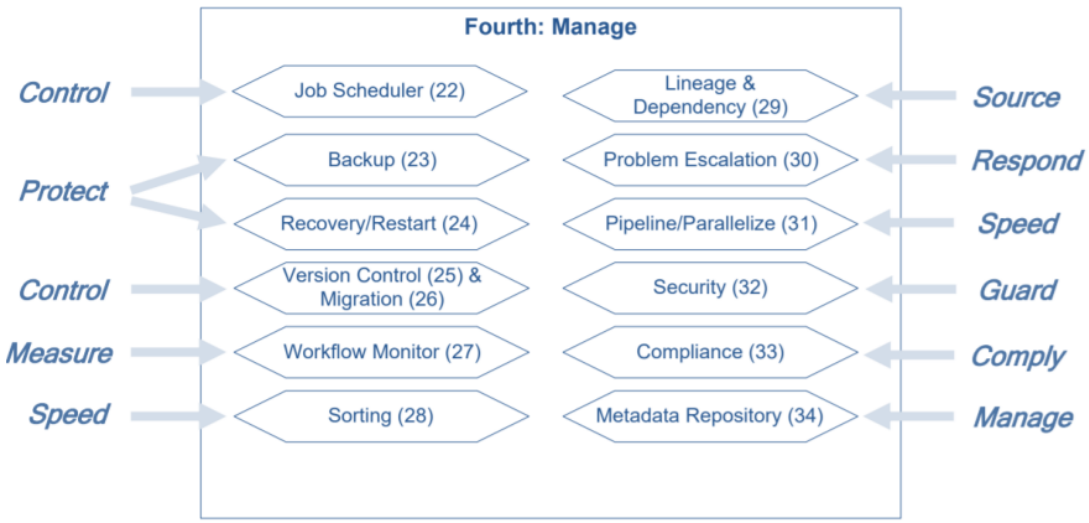
31. **Sistema de paralelismo/pipeline**: divide o processo de ETL em tarefas menores que podem ser executadas em paralelo, aumentando a eficiência e o desempenho do processo de ETL. O sistema de pipeline é usado para definir a ordem de execução das tarefas, bem como para fornecer informações sobre o estado do pipeline em tempo real.

32. **Sistema de segurança**: garante que somente pessoas autorizadas tenham acesso aos dados, evitando possíveis violações de segurança. Esse subsistema é responsável por gerenciar a autenticação, autorização e criptografia de dados sensíveis durante todo o processo de ETL.

33. **Gerenciamento de conformidade**: garante que o processo de ETL esteja em conformidade com as regulamentações governamentais e as políticas internas da empresa.

34. **Gerenciamento de repositório de metadados**: responsável por armazenar informações sobre o processo de ETL, incluindo definições de fontes de dados, transformações e destinos.

Veja os subsistemas de gestão na figura abaixo:



11225354498 - Maria Vitória Gonçalves Vieira

Processo de ETL

O processo de ETL é composto por uma série de etapas que visam a extrair, transformar e carregar dados de diferentes fontes em um destino final, seguindo um fluxo de trabalho padronizado e eficiente. As principais etapas desse processo são:

Desenhar o plano de alto nível: Essa etapa envolve a definição da estratégia geral de ETL, incluindo a escolha da ferramenta ETL e o desenho do fluxo de trabalho. Nessa fase, é importante definir claramente os objetivos do projeto, identificar as fontes de dados, os sistemas de destino e os requisitos de transformação e limpeza de dados.

Escolher uma ferramenta ETL: Nesta etapa, é necessário escolher a ferramenta ETL que melhor atende aos requisitos do projeto. Veja as principais vantagens de se utilizar uma ferramenta especializada em ETL:

Característica	Descrição
Auto documentação	**Vem pelo uso de uma ferramenta gráfica. Um sistema codificado manualmente é geralmente uma confusão impenetrável de tabelas de preparação, scripts SQL, procedimentos armazenados e scripts do sistema operacional.**
Metadados	**Para todas as etapas do processo ETL**
Controle de versão	**para ambientes com vários desenvolvedores e que permite voltar e restaurar versões consistentes.**
Lógica de transformação avançada	**Como algoritmos de correspondência difusa (fuzzy), acesso integrado a rotinas de deduplicação de nome e endereço, e algoritmos de mineração de dados.**
Melhor desempenho	**Poucos desenvolvedores de SQL são realmente especialistas em como usar o banco de dados relacional para manipular volumes de dados extremamente grandes com excelente desempenho. É melhor deixar isso para a ferramenta**
Recursos de processamento	**incluindo o paralelismo automático de tarefas e failover automático quando um recurso de processamento fica indisponível. Conversão (em uma etapa) dos módulos de transformação de dados virtualizados em seus equivalentes físicos.**

Existem várias ferramentas ETL disponíveis no mercado, como o Microsoft SSIS, o Talend, o Informatica PowerCenter, o Oracle Data Integrator e o IBM InfoSphere DataStage. Cada uma dessas ferramentas tem suas próprias vantagens e desvantagens, e a escolha da ferramenta ideal dependerá das necessidades específicas de cada projeto.

Desenvolver estratégias padronizadas: Para garantir a qualidade dos dados e a eficiência do processo, é importante desenvolver estratégias padronizadas para a extração, transformação e carga de dados. Isso inclui definir padrões de nomenclatura, formatos de arquivo, processos de limpeza e conformidade de dados, entre outros.

Drill Down by Target Table: Nesta fase, é necessário analisar as tabelas de destino e definir as estratégias de extração, transformação e carga para cada uma delas. Isso inclui identificar

11225354498 - Maria Vitória Gonçalves Vieira

as fontes de dados, definir as regras de transformação e limpeza de dados, e mapear os campos de origem para os campos de destino.

Preencher tabelas de dimensões com dados históricos: Quando se trata de um novo projeto, pode ser necessário carregar dados históricos em tabelas de dimensões. Essa etapa envolve a extração de dados de várias fontes, a transformação dos dados para corresponder aos padrões de nomenclatura e formato de dados, e a carga dos dados em tabelas de dimensões.

Executar a carga histórica da tabela de fatos: Nesta etapa, a carga inicial da tabela de fatos é executada. A maior preocupação durante a carga histórica é o grande volume de dados, às vezes milhares de vezes maior que a carga incremental diária. Por outro lado, você tem o luxo de carregar em uma tabela que não está em produção. Se levar vários dias para carregar os dados históricos, isso geralmente é tolerável.

Processamento Incremental da Tabela de Dimensão: Após a carga inicial das tabelas de dimensão, é necessário executar o processamento incremental para atualizar as tabelas de dimensão com novos dados. Se possível, construa o uma tarefa para extrair somente as linhas que foram alteradas. Isso é particularmente fácil e valioso se o sistema de origem mantiver um indicador do tipo de mudança.

8. **Processamento Incremental da Tabela de Fatos**: A maioria dos bancos de dados do data warehouse é grande demais para substituir inteiramente as tabelas de fatos em uma única janela de carregamento. Em vez disso, linhas de fatos novas e atualizadas são processadas de forma incremental. É muito mais eficiente carregar de forma incremental apenas os registros que foram adicionados ou atualizados desde o carregamento anterior. Isso é especialmente verdadeiro em um sistema de jornal diário em que o histórico nunca é alterado e somente ajustes no período atual são permitidos.

9. **Tabela agregada e Cargas OLAP**: Nesta etapa, as tabelas agregadas são criadas para melhorar o desempenho das consultas OLAP. Isso envolve a agregação de dados em níveis diferentes de granularidade e a criação de índices para acelerar o acesso aos dados.

10. **Operação e Automação do Sistema ETL**: A última etapa envolve a operação e automação do sistema ETL. Depois que o ETL é configurado e funcionando corretamente, é necessário automatizar o processo de extração, transformação e carga. Isso envolve a programação de jobs ETL, a criação de agendamentos e a configuração de notificações e alertas para que as equipes de operações possam monitorar e solucionar problemas de forma proativa. O gerenciamento de logs e o controle de versão também são importantes para garantir que o sistema esteja sempre em um estado confiável e que os problemas possam ser facilmente rastreados e corrigidos

11225354498 - Maria Vitória Gonçalves Vieira

Apêndice: Funções e Técnicas Relacionadas

O ETL está intimamente relacionado a várias outras funções, processos e técnicas de *data integration*. Vamos listar aqui esses conceitos relacionados com o assunto:

Data mapping: O mapeamento de dados é parte do processo de transformação. Ele fornece instruções detalhadas para uma aplicação sobre como obter os dados necessários para processar. Também descreve qual campo de origem é mapeado para qual campo de destino. Por exemplo, o terceiro atributo de um feed de dados de atividades de um website pode ser o nome de usuário; o quarto pode ser o horário de quando a atividade aconteceu e o quinto pode ser o produto no qual o usuário clicou.

Scripts ETL: É um método que automatiza os scripts (conjunto de instruções) que são executados no plano de fundo para mover e transformar os dados.

ETL versus ELT: No princípio, havia o ETL. Então, as empresas adicionaram o ELT, um método complementar. ELT extrai dados de um sistema-fonte, os carrega em um sistema de destino e, então, usa o poder de processamento do sistema-fonte para conduzir as transformações. Isso acelera o processamento de dados porque acontece onde os dados estão.

Data quality: Antes que os dados sejam integrados, um ambiente de teste é normalmente criado onde eles possam ser limpos e padronizados, por exemplo SP e São Paulo são termos iguais que devem ser padronizados, assim como Senhor e Sr. ou Bia e Beatriz. Outrossim, endereços possam ser verificados e duplicatas, removidas. Muitas soluções ainda são independentes, mas procedimentos de data quality podem agora ser executados como uma das transformações no processo de data integration.

Agendando e processando: Ferramentas e tecnologias ETL podem fornecer tanto agendamento em lote quanto capacidades em tempo real. Elas podem também processar dados em altos volumes no servidor ou podem reduzir o processamento para o nível do banco de dados. Essa abordagem de processamento em um banco de dados, em vez de em um mecanismo especializado, evita duplicação dos dados e a necessidade de usar capacidades extras na plataforma do banco de dados.

Processamento em lote: ETL normalmente se refere a um processamento em lote que envolve a movimentação de grandes volumes de dados entre dois sistemas durante o que é chamado de "janela". Nesse período de tempo determinado – por exemplo, entre o meio-dia e a uma da tarde – nenhuma ação pode ocorrer com o sistema-fonte, ou alvo, enquanto os dados são sincronizados.

Master data management - MDM: é o processo de unir os dados para criar uma visão única deles, através de múltiplas fontes. Ele inclui tanto ETL quanto capacidades de data

11225354498 - Maria Vitória Gonçalves Vieira

integration para misturar as informações e criar um “registro de ouro” ou um “melhor registro”.

Data virtualization: Virtualização é um método ágil de misturar os dados para criar um panorama virtual sem movê-los. Data virtualization difere de ETL porque, embora mapeamento e combinação de dados ainda ocorram, não há a necessidade de uma tabela de teste física para armazenar os resultados. Isso porque o panorama é geralmente armazenado na memória e em cachê para melhorar a performance.

Event stream processing and ETL: Quando a velocidade dos dados aumenta para milhões de eventos por segundo, event stream processing pode ser usado para monitorar e processar fluxos de dados, e ajudar a tomar decisões mais rapidamente. Um exemplo no setor de produção de energia é utilizar análises preditivas em fluxos de dados para detectar quando uma bomba submersa precisa de reparo, reduzindo o tempo de inatividade, além do escopo e do tamanho do dano à bomba.

APOSTA ESTRATÉGICA

A ideia desta seção é apresentar os pontos do conteúdo que mais possuem chances de serem cobrados em prova, considerando o histórico de questões da banca em provas de nível semelhante à nossa, bem como as inovações no conteúdo, na legislação e nos entendimentos doutrinários e jurisprudenciais[1].

Master Data Management (MDM) é uma abordagem estratégica e tecnológica que visa a gestão centralizada e coerente dos dados mestres de uma organização, como clientes, produtos, fornecedores e outros elementos essenciais para as operações e análises de negócios. O objetivo principal do MDM é garantir que os dados mestres sejam precisos, consistentes e confiáveis em todas as áreas da empresa, eliminando redundâncias e inconsistências que possam surgir devido à duplicação de dados em sistemas isolados. Para isso, o MDM utiliza técnicas e ferramentas para identificar, integrar, limpar e sincronizar os dados mestres, criando uma única versão da verdade que pode ser compartilhada e utilizada de forma consistente em toda a organização.

Além disso, o MDM também está relacionado à governança de dados, estabelecendo políticas, processos e controles para garantir a qualidade, segurança e conformidade dos dados mestres. Isso inclui a definição de regras de negócios, a gestão de metadados, o controle de acesso e outras práticas que visam a manter a integridade e a confiabilidade dos dados mestres ao longo do tempo. Com uma estratégia de MDM bem implementada, as

[1] Vale deixar claro que nem sempre será possível realizar uma aposta estratégica para um determinado assunto, considerando que às vezes não é viável identificar os pontos mais prováveis de serem cobrados a partir de critérios objetivos ou minimamente razoáveis.

11225354498 - Maria Vitória Gonçalves Vieira

organizações podem melhorar a eficiência operacional, tomar decisões mais informadas e proporcionar uma experiência consistente aos clientes, contribuindo para o sucesso e a competitividade nos mercados em que atuam.

QUESTÕES ESTRATÉGICAS

Nesta seção, apresentamos e comentamos uma amostra de questões objetivas selecionadas estrategicamente: são questões com nível de dificuldade semelhante ao que você deve esperar para a sua prova e que, em conjunto, abordam os principais pontos do assunto.

A ideia, aqui, não é que você fixe o conteúdo por meio de uma bateria extensa de questões, mas que você faça uma boa revisão global do assunto a partir de, relativamente, poucas questões

1. (FGV / TJDFT – Análise de Sistemas – 2022) Lino precisa preparar um grande volume de dados para minerar realizando operações de limpeza, adequação de formato, exclusão de brancos e inclusão de novos atributos derivados. Para realizar o pré-processamento dos dados, Lino deve usar uma ferramenta do tipo:

a) ETL
b) OLAP
c) Apriori
d) Data Mart
e) Data Lake

Comentários:

O pré-processamento a ser realizado por Lino é feito por meio de ferramentas de ETL (Extract, Transform, Load) – particularmente na etapa de Transformação. Essa etapa é responsável por compilar, converter, reformatar, limpar os dados, entre outros.

Gabarito: A

---

2. (FGV / ALERJ – 2017) Daniel está desenvolvendo um Data Warehouse para analisar os dados do Censo Escolar. A fonte de dados está em um arquivo CSV e descrita em um documento, conforme parcialmente ilustrado nas figuras a seguir.

Para carregar esses dados no Data Warehouse com a descrição dos turnos no lugar de seu código, Daniel deve desenvolver um programa para ler os dados do arquivo, realizar transformações e carregar o resultado no banco de dados.

A ferramenta a ser utilizada por Daniel é:

11225354498 - Maria Vitória Gonçalves Vieira

a) ETL
b) OLAP
c) Data Mining
d) ODBC
e) XSLT

Comentários:

Daniel quer carregar esses dados no Data Warehouse, no entanto ele quer carregar a descrição dos turnos ao invés de seu código. Para transformar esses valores de código em descrição antes de carregar no Data Warehouse, Daniel deve fazer uma ETL: extrai os dados do Arquivo CSV, realiza algumas transformações (Código > Descrição) e carrega no DW.

Gabarito: A

---

3. **(FGV / SMF-RJ – 2023)** No ambiente de Data Warehousing da SMFP/RJ, os dados são extraídos de diversas fontes e integrados para apoiar a fiscalização de rendas por meio do desenvolvimento de diversos artefatos de dados. Antes de começar as análises nesse ambiente, o fiscal de rendas Inácio fez consultas sobre o seu conteúdo, por exemplo:

• DW_Tributos, banco de dados analítico do tipo Data Warehouse que integra dados sobre os tributos arrecadados do Município do Rio de Janeiro.

• TP_EMPRESA, Caractere, 1, atributo que descreve o tipo da empresa contendo os seguintes valores: M - MEI ou S - Simples Nacional, e faz parte da tabela TB _EMPRESA.

• RL_Sit_Fiscal, relatório sobre a situação fiscal das empresas do Município do Rio de Janeiro.

O componente do ambiente de Data Warehousing, utilizado por Inácio, que foi desenvolvido para apoiar consultas sobre a descrição de cada artefato de dado, é:

a) ETL;

b) Métricas;

c) Dashboard;

d) Dimensões de Dados;

11225354498 - Maria Vitória Gonçalves Vieira

e) Repositório de Metadados.

Comentários:

(a) Errado. ETL (Extract, Transform, Load): O ETL é um processo fundamental no ambiente de Data Warehousing, mas não é utilizado para apoiar consultas sobre a descrição de artefatos de dados. Em vez disso, o ETL é responsável por extrair dados de diversas fontes, transformá-los para atender às necessidades analíticas e carregá-los no Data Warehouse.

(b) Errado. s métricas são medidas quantitativas usadas para avaliar o desempenho ou o comportamento dos dados no Data Warehouse. Elas são úteis para análises, mas não são usadas para descrever a natureza ou a estrutura dos artefatos de dados.

(c) Errado. Um dashboard é uma interface visual que apresenta informações resumidas e métricas em um formato fácil de entender. Embora os dashboards sejam usados para apresentar informações aos usuários, eles não são especificamente projetados para descrever a natureza dos artefatos de dados, como tabelas ou campos.

(d) Errado. As dimensões de dados são estruturas que organizam os dados em categorias ou hierarquias, tornando mais fácil a análise e a consulta dos dados. Embora sejam importantes para a análise, as dimensões não são usadas para descrever a natureza dos próprios artefatos de dados.

(e) Correto. Um repositório de metadados é uma parte fundamental do ambiente de Data Warehousing, pois armazena informações detalhadas sobre os dados, sua origem, significado, estrutura e relacionamentos. Isso permite que os usuários consultem e compreendam os metadados associados aos dados armazenados no Data Warehouse, facilitando a análise e a interpretação dos dados.

Gabarito: Letra E

11225354498 - Maria Vitória Gonçalves Vieira

4. **(FGV / TJ-RN - 2023)** Para integrar os dados de diversas fontes, Julia desenvolveu um ETL para executar ações sobre os dados como: extrair, limpar, agregar, transformar e carregar dados em um banco de dados destino visando apoiar análises históricas. Para implementar as ações sobre os dados em um ETL, Julia utilizou:

a) steps e fluxos de dados;

b) repositório de metadados;

c) sequências temporais;

d) regras de associação;

e) data mining.

Comentários:

No processo de ETL, os dados são extraídos de diversas fontes, como bancos de dados, arquivos, APIs, etc. Em seguida, esses dados passam por transformações, onde são limpos, agregados, enriquecidos ou modificados de acordo com as necessidades da análise. Por fim, os dados transformados são carregados em um banco de dados destino, onde estarão disponíveis para as análises históricas.

No contexto do ETL, os steps representam as etapas individuais do processo de extração, transformação e carga. Cada step corresponde a uma ação específica sobre os dados, como filtrar, formatar, calcular, entre outras. Esses steps são organizados em fluxos de dados, que definem a sequência e a lógica das ações a serem executadas.

Gabarito: Letra A

5. **(FGV / CGE-SC - 2023)** As informações analiticamente úteis das fontes de dados operacionais (das operações do dia a dia do negócio) são carregadas no Data Warehouse por meio do processo de ETL. Um dos recursos úteis em um DW é poder observar um mesmo item de dimensão em vários instantes de tempo (timestamps), como, por exemplo, observar o preço de venda de um produto ao longo dos anos.

11225354498 - Maria Vitória Gonçalves Vieira

Assinale a opção que indica a técnica que torna possível a disposição desse recurso.

a) A supressão, no Data Warehouse, das chaves primárias do bando de dados operacional.

b) A criação de chaves primárias compostas por um atributo de chave substituta e um de chave primária do banco de dados operacional.

c) A substituição, e consequente supressão, das chaves primárias do banco de dados operacional por chaves substitutas no Data Warehouse.

d) A criação de chaves primárias substitutas no Data Warehouse, mantendo as chaves primárias do banco de dados operacional como atributos únicos no Data Warehouse.

e) A criação de chaves primárias substitutas no Data Warehouse, mantendo as chaves primárias do banco de dados operacional como atributos não chave no Data Warehouse.

Comentários:

Nenhuma das alternativas está diretamente relacionada à disposição de observar um mesmo item de dimensão em vários instantes de tempo, exceto a alternativa (e). Já por meio de chaves substitutas, é possível observar um mesmo item de dimensão em diversos instantes de tempo, enquanto as chaves primárias do banco de dados operacional são mantidas como atributos não chave no Data Warehouse.

Essa abordagem permite que cada registro no Data Warehouse seja identificado por uma chave primária substituta única, que é gerada internamente no processo de ETL. Essa chave primária substituta é usada para vincular os fatos com as dimensões e permite a rastreabilidade temporal dos dados. Ao mesmo tempo, as chaves primárias originais do banco de dados operacional são mantidas como atributos não chave no DW, permitindo a

11225354498 - Maria Vitória Gonçalves Vieira

referência aos dados históricos e a possibilidade de observar um mesmo item de dimensão em diferentes instantes de tempo.

Gabarito: Letra E

QUESTIONÁRIO DE REVISÃO E APERFEIÇOAMENTO

A ideia do questionário é elevar o nível da sua compreensão no assunto e, ao mesmo tempo, proporcionar uma outra forma de revisão de pontos importantes do conteúdo, a partir de perguntas que exigem respostas subjetivas.

São questões um pouco mais desafiadoras, porque a redação de seu enunciado não ajuda na sua resolução, como ocorre nas clássicas questões objetivas.

O objetivo é que você realize uma auto explicação mental de alguns pontos do conteúdo, para consolidar melhor o que aprendeu ;)

Além disso, as questões objetivas, em regra, abordam pontos isolados de um dado assunto. Assim, ao resolver várias questões objetivas, o candidato acaba memorizando pontos isolados do conteúdo, mas muitas vezes acaba não entendendo como esses pontos se conectam.

Assim, no questionário, buscaremos trazer também situações que ajudem você a conectar melhor os diversos pontos do conteúdo, na medida do possível.

É importante frisar que não estamos adentrando em um nível de profundidade maior que o exigido na sua prova, mas apenas permitindo que você compreenda melhor o assunto de modo a facilitar a resolução de questões objetivas típicas de concursos, ok?

Nosso compromisso é proporcionar a você uma revisão de alto nível!

Vamos ao nosso questionário:

Perguntas

1. O que significa a sigla ETL e quais são suas principais etapas?

2. Quais são os principais desafios enfrentados no processo de ETL?

3. O que é o componente de extração no processo de ETL?

4. Quais são os três subsistemas da extração?

11225354498 - Maria Vitória Gonçalves Vieira

5. Quais são algumas ferramentas usadas para o componente de extração?

6. O que é o componente de limpeza e conformidade no processo de ETL?

7. Quais são os cinco subsistemas da limpeza e conformidade de dados?

8. Qual é o benefício de usar o subsistema de deduplicação durante o processo de limpeza e conformidade?

9. O que é o componente de entrega no processo de ETL?

10. Quais são alguns dos subsistemas comuns da entrega?

11. O que é o componente de gestão no processo de ETL?

12. Quais são alguns dos subsistemas comuns de gestão?

13. O que é o processo de Master Data Management (MDM)?

14. O que é o processamento em lote?

15. O que é Data Quality?

16. Quais são alguns dos principais problemas de qualidade de dados?

17. O que é Data Virtualization?

18. O que é Data Mapping?

19. O que é Event Stream Processing (ESP)?

20. Qual é a diferença entre ETL e ELT?

Perguntas e Respostas

1. O que significa a sigla ETL e quais são suas principais etapas?

Resposta: ETL significa Extração, Transformação e Carga. Suas principais etapas são extração de dados, limpeza e conformidade de dados, entrega de dados e gestão do ETL.

2. Quais são os principais desafios enfrentados no processo de ETL?

11225354498 - Maria Vitória Gonçalves Vieira

Resposta: Alguns dos principais desafios incluem a complexidade do processo de transformação, a integração com diferentes fontes de dados e a manutenção da qualidade dos dados.

3. O que é o componente de extração no processo de ETL?

Resposta: O componente de extração é responsável por coletar dados de várias fontes de dados diferentes e prepará-los para o processo de transformação.

4. Quais são os três subsistemas da extração?

Resposta: Os três subsistemas da extração são Data Profiling, Captura de Alterações nos Dados e Sistema de Extração.

5. Quais são algumas ferramentas usadas para o componente de extração?

Resposta: Algumas ferramentas comuns usadas para o componente de extração incluem o Oracle Data Integrator (ODI), o Informatica PowerCenter e o Microsoft SQL Server Integration Services (SSIS).

6. O que é o componente de limpeza e conformidade no processo de ETL?

Resposta: O componente de limpeza e conformidade é responsável por garantir que os dados coletados durante o processo de extração estejam livres de erros, inconsistências e duplicatas.

7. Quais são os cinco subsistemas da limpeza e conformidade de dados?

Resposta: Os cinco subsistemas da limpeza e conformidade de dados são Sistema de Limpeza de Dados, Esquema de Eventos de Erro, Dimensão de Auditoria, Sistema de Deduplicação e Sistema de Conformidade.

8. Qual é o benefício de usar o subsistema de deduplicação durante o processo de limpeza e conformidade?

Resposta: O subsistema de deduplicação ajuda a evitar a duplicação de dados, reduzindo assim a quantidade de dados desnecessários e aumentando a eficiência do processo.

9. O que é o componente de entrega no processo de ETL?

Resposta: O componente de entrega é responsável por carregar os dados limpos e transformados em um data warehouse ou outro sistema de destino.

10. Quais são alguns dos subsistemas comuns da entrega?

Resposta: Alguns dos subsistemas comuns da entrega incluem o Gerenciador da Alteração Lenta da Dimensão, o Gerador de Chave Substituta e a Construção de Tabelas Agregadas.



11225354498 - Maria Vitória Gonçalves Vieira

11. O que é o componente de gestão no processo de ETL?

Resposta: O componente de gestão é responsável por gerenciar e monitorar todo o processo de ETL, garantindo que as tarefas sejam concluídas com sucesso e de forma eficiente.

12. Quais são alguns dos subsistemas comuns de gestão?

Resposta: Alguns dos subsistemas comuns de gestão incluem o Agendador de Jobs, o Sistema de Backup e o Monitor de Workflow.

13. O que é o processo de Master Data Management (MDM)?

Resposta: O processo de Master Data Management envolve a gestão centralizada dos dados de referência da empresa, como clientes, produtos e fornecedores, para garantir que esses dados sejam consistentes e precisos em todas as áreas da organização.

14. O que é o processamento em lote?

Resposta: O processamento em lote é uma técnica de processamento de dados em que um grande volume de dados é processado em lotes, ou seja, em um conjunto de registros de uma vez.

15. O que é Data Quality?

Resposta: Data Quality se refere à avaliação e garantia da qualidade dos dados, incluindo sua precisão, integridade, consistência e relevância para uso.

16. Quais são alguns dos principais problemas de qualidade de dados?

Resposta: Alguns problemas comuns de qualidade de dados incluem duplicatas, erros de digitação, inconsistências, falta de padronização e valores ausentes.

17. O que é Data Virtualization?

Resposta: Data Virtualization é uma abordagem que permite acessar e integrar dados de várias fontes heterogêneas como se estivessem em um único local, sem a necessidade de mover ou replicar os dados.

18. O que é Data Mapping?

Resposta: Data Mapping é o processo de associar campos ou elementos de dados de uma fonte para seus equivalentes na estrutura de destino, permitindo a transformação e migração corretas dos dados.

19. O que é Event Stream Processing (ESP)?



11225354498 - Maria Vitória Gonçalves Vieira

Resposta: Event Stream Processing é uma abordagem de processamento em tempo real que envolve a análise e o processamento contínuo de fluxos de eventos em tempo real para obter insights imediatos.

20. Qual é a diferença entre ETL e ELT?

Resposta: ETL significa Extração, Transformação e Carga, enquanto ELT significa Extração, Carga e Transformação. A principal diferença é que, no ELT, a transformação dos dados ocorre após o processo de carga, enquanto no ETL, a transformação ocorre antes da carga

LISTA DE QUESTÕES ESTRATÉGICAS

1. (FGV / TJDFT – Análise de Sistemas – 2022) Lino precisa preparar um grande volume de dados para minerar realizando operações de limpeza, adequação de formato, exclusão de brancos e inclusão de novos atributos derivados. Para realizar o pré-processamento dos dados, Lino deve usar uma ferramenta do tipo:

a) ETL
b) OLAP
c) Apriori
d) Data Mart
e) Data Lake

---

2. (FGV / ALERJ – 2017) Daniel está desenvolvendo um Data Warehouse para analisar os dados do Censo Escolar. A fonte de dados está em um arquivo CSV e descrita em um documento, conforme parcialmente ilustrado nas figuras a seguir.

Para carregar esses dados no Data Warehouse com a descrição dos turnos no lugar de seu código, Daniel deve desenvolver um programa para ler os dados do arquivo, realizar transformações e carregar o resultado no banco de dados.

A ferramenta a ser utilizada por Daniel é:

a) ETL
b) OLAP
c) Data Mining
d) ODBC
e) XSLT

3. **(FGV / SMF-RJ – 2023)** No ambiente de Data Warehousing da SMFP/RJ, os dados são extraídos de diversas fontes e integrados para apoiar a fiscalização de rendas por meio do

11225354498 - Maria Vitória Gonçalves Vieira

desenvolvimento de diversos artefatos de dados. Antes de começar as análises nesse ambiente, o fiscal de rendas Inácio fez consultas sobre o seu conteúdo, por exemplo:

• DW_Tributos, banco de dados analítico do tipo Data Warehouse que integra dados sobre os tributos arrecadados do Município do Rio de Janeiro.

• TP_EMPRESA, Caractere, 1, atributo que descreve o tipo da empresa contendo os seguintes valores: M - MEI ou S - Simples Nacional, e faz parte da tabela TB _EMPRESA.

• RL_Sit_Fiscal, relatório sobre a situação fiscal das empresas do Município do Rio de Janeiro.

O componente do ambiente de Data Warehousing, utilizado por Inácio, que foi desenvolvido para apoiar consultas sobre a descrição de cada artefato de dado, é:

a) ETL;

b) Métricas;

c) Dashboard;

d) Dimensões de Dados;

e) Repositório de Metadados.

4. **(FGV / TJ-RN - 2023)** Para integrar os dados de diversas fontes, Julia desenvolveu um ETL para executar ações sobre os dados como: extrair, limpar, agregar, transformar e carregar dados em um banco de dados destino visando apoiar análises históricas. Para implementar as ações sobre os dados em um ETL, Julia utilizou:

a) steps e fluxos de dados;

b) repositório de metadados;

c) sequências temporais;

d) regras de associação;

e) data mining.

11225354498 - Maria Vitória Gonçalves Vieira

5. **(FGV / CGE-SC - 2023)** As informações analiticamente úteis das fontes de dados operacionais (das operações do dia a dia do negócio) são carregadas no Data Warehouse por meio do processo de ETL. Um dos recursos úteis em um DW é poder observar um mesmo item de dimensão em vários instantes de tempo (timestamps), como, por exemplo, observar o preço de venda de um produto ao longo dos anos.

Assinale a opção que indica a técnica que torna possível a disposição desse recurso.

a) A supressão, no Data Warehouse, das chaves primárias do bando de dados operacional.

b) A criação de chaves primárias compostas por um atributo de chave substituta e um de chave primária do banco de dados operacional.

c) A substituição, e consequente supressão, das chaves primárias do banco de dados operacional por chaves substitutas no Data Warehouse.

d) A criação de chaves primárias substitutas no Data Warehouse, mantendo as chaves primárias do banco de dados operacional como atributos únicos no Data Warehouse.

e) A criação de chaves primárias substitutas no Data Warehouse, mantendo as chaves primárias do banco de dados operacional como atributos não chave no Data Warehouse.

Gabaritos

1. A
2. A
3. E
4. A
5. E

11225354498 - Maria Vitória Gonçalves Vieira

Questões Adicionais

As questões apresentadas a seguir integram o Banco de Questões do Passo Estratégico. Recomenda-se utilizá-las como um recurso complementar para a prática e consolidação dos conhecimentos adquiridos no material teórico, de acordo com o estilo adotado pela banca organizadora.

Bom estudo!

1. O que é o processamento de fluxo de eventos em tempo real (Event Stream Processing)?

A) Transformação dos dados para análise de dados históricos
B) Monitoramento em tempo real de eventos e ações subsequentes
C) Extração dos dados de fontes externas
D) Carregamento dos dados no data warehouse
E) Migração dos dados entre sistemas de banco de dados

2. Qual das seguintes opções NÃO é um componente do processo ETL (Extração, Transformação e Carregamento) em Business Intelligence?

A) Extração: obtenção dos dados brutos das fontes
B) Transformação: alteração dos dados para um formato que possa ser utilizado para análise
C) Carregamento: entrada dos dados transformados em um data warehouse
D) Monitoramento: acompanhamento dos dados em tempo real e realização ações subsequentes
E) Migração: transferência de dados entre sistemas de banco de dados

3. Qual é o papel do sistema de gerenciamento de repositório de metadados no processo de ETL?

A) Ele armazena e gerencia informações sobre os dados, incluindo origem, formato e transformação
B) Ele é responsável por executar consultas nos dados em tempo real
C) Ele monitora a segurança e o acesso aos dados
D) Ele realiza a compressão dos dados para economizar espaço de armazenamento
E) Ele gerencia os backups dos dados extraídos

4. Qual é o objetivo do processamento incremental no processo de ETL?

A) Carregar todos os dados de uma só vez
B) Garantir a conformidade dos dados com as regulamentações
C) Processar apenas os dados alterados desde a última carga
D) Realizar a extração dos dados de várias fontes
E) Melhorar a segurança dos dados durante a transformação

5. Qual é a principal função da etapa de extração no processo de ETL?

11225354498 - Maria Vitória Gonçalves Vieira

A) Limpar e transformar os dados
B) Carregar os dados no data warehouse
C) Garantir a segurança dos dados
D) Realizar consultas nos dados
E) Gerenciar o sistema de ETL

6. Por que a fase de limpeza de dados é crítica no processo de ETL?

A) Para reduzir o tempo de processamento dos dados
B) Para garantir a segurança dos dados durante a extração
C) Para facilitar a migração dos dados para o cloud
D) Para eliminar inconsistências e garantir a qualidade dos dados
E) Para aumentar a velocidade das consultas no data warehouse

7. O que é o Master Data Management (MDM) em um ambiente de data warehousing?

A) Processo de extração de dados de várias fontes
B) Gestão centralizada dos dados de referência da organização
C) Técnica de limpeza e conformidade de dados
D) Sistema de backup e recuperação de dados
E) Criação de tabelas agregadas para análise de dados

8. Qual é o papel do subsistema de gerenciamento de conformidade no processo de ETL e como ele garante que os dados estejam em conformidade com as regulamentações e políticas internas da organização?

A) Realizar a compressão dos dados para otimização de espaço de armazenamento
B) Monitorar continuamente a segurança dos dados durante todas as fases do ETL
C) Executar consultas de alta performance nos dados conformados
D) Facilitar a integração de dados de fontes externas sem necessidade de validação
E) Garantir que os dados carregados no data warehouse estejam em conformidade com as regulamentações e políticas internas, aplicando regras de conformidade específicas durante o processo de transformação

9. No contexto de Master Data Management (MDM), qual é uma prática essencial para garantir a qualidade dos dados mestres?

A) Realizar a compressão dos dados
B) Executar consultas em tempo real
C) Implementar regras de negócios e validação de dados
D) Facilitar a migração de dados para o cloud
E) Garantir backups frequentes dos dados

10. Complete a frase a seguir: A etapa de _____ no processo de ETL é responsável por coletar dados de várias fontes e garantir que eles sejam capturados de forma eficiente, sem realizar alterações iniciais antes da transformação e carga.

11225354498 - Maria Vitória Gonçalves Vieira

A) extração
B) transformação
C) validação
D) integração
E) padronização

GABARITOS E COMENTÁRIOS

1. O que é o processamento de fluxo de eventos em tempo real (Event Stream Processing)?

A) Transformação dos dados para análise de dados históricos
B) Monitoramento em tempo real de eventos e ações subsequentes
C) Extração dos dados de fontes externas
D) Carregamento dos dados no data warehouse
E) Migração dos dados entre sistemas de banco de dados

Gabarito: B

Comentários: O processamento de fluxo de eventos em tempo real refere-se ao monitoramento em tempo real de eventos e ações subsequentes baseadas nesses eventos, permitindo uma resposta rápida a situações em tempo real.

2. Qual das seguintes opções NÃO é um componente do processo ETL (Extração, Transformação e Carregamento) em Business Intelligence?

A) Extração: obtenção dos dados brutos das fontes
B) Transformação: alteração dos dados para um formato que possa ser utilizado para análise
C) Carregamento: entrada dos dados transformados em um data warehouse
D) Monitoramento: acompanhamento dos dados em tempo real e realização ações subsequentes
E) Migração: transferência de dados entre sistemas de banco de dados

Gabarito: E

Comentários: A opção correta é a letra E. O processo ETL em Business Intelligence se refere à Extração (obtendo dados brutos), Transformação (alterando os dados para um formato utilizável) e Carregamento (coloque os dados transformados em um depósito de dados). O monitoramento em tempo real e as ações subsequentes (letra D), embora possam fazer parte de um processo de Business Intelligence mais amplo, não são parte do processo ETL, e a migração de dados (letra E) se refere a um processo diferente de transferir dados de um sistema para outro, mas não necessariamente para análise. As letras A, B e C são todas partes do processo ETL e, portanto, estão incorretas.

3. Qual é o papel do sistema de gerenciamento de repositório de metadados no processo de ETL?

11225354498 - Maria Vitória Gonçalves Vieira

A) Ele armazena e gerencia informações sobre os dados, incluindo origem, formato e transformação
B) Ele é responsável por executar consultas nos dados em tempo real
C) Ele monitora a segurança e o acesso aos dados
D) Ele realiza a compressão dos dados para economizar espaço de armazenamento
E) Ele gerencia os backups dos dados extraídos

Gabarito: A

Comentários: O sistema de gerenciamento de repositório de metadados no processo de ETL armazena e gerencia informações detalhadas sobre os dados, como origem, formato e transformações aplicadas, permitindo a rastreabilidade e compreensão dos dados ao longo do processo.

4. Qual é o objetivo do processamento incremental no processo de ETL?

A) Carregar todos os dados de uma só vez
B) Garantir a conformidade dos dados com as regulamentações
C) Processar apenas os dados alterados desde a última carga
D) Realizar a extração dos dados de várias fontes
E) Melhorar a segurança dos dados durante a transformação

Gabarito: C

Comentários: O processamento incremental no processo de ETL tem como objetivo processar e carregar apenas os dados que foram alterados desde a última carga, economizando tempo e recursos.

5. Qual é a principal função da etapa de extração no processo de ETL?

A) Limpar e transformar os dados
B) Carregar os dados no data warehouse
C) Garantir a segurança dos dados
D) Realizar consultas nos dados
E) Gerenciar o sistema de ETL

Gabarito: A

Comentários: A etapa de extração é responsável por coletar dados das fontes de origem sem alterá-los, preparando-os para a etapa de transformação.

6. Por que a fase de limpeza de dados é crítica no processo de ETL?

A) Para reduzir o tempo de processamento dos dados
B) Para garantir a segurança dos dados durante a extração
C) Para facilitar a migração dos dados para o cloud

11225354498 - Maria Vitória Gonçalves Vieira

D) Para eliminar inconsistências e garantir a qualidade dos dados
E) Para aumentar a velocidade das consultas no data warehouse

Gabarito: D

Comentários: A fase de limpeza de dados no processo de ETL é crítica porque elimina erros, inconsistências e duplicatas, garantindo que os dados carregados no sistema de destino sejam precisos e confiáveis.

7. O que é o Master Data Management (MDM) em um ambiente de data warehousing?

A) Processo de extração de dados de várias fontes
B) Gestão centralizada dos dados de referência da organização
C) Técnica de limpeza e conformidade de dados
D) Sistema de backup e recuperação de dados
E) Criação de tabelas agregadas para análise de dados

Gabarito: B

Comentários: O Master Data Management (MDM) é a prática de gerenciamento centralizado dos dados de referência essenciais da organização, garantindo a consistência e qualidade desses dados.

8. Qual é o papel do subsistema de gerenciamento de conformidade no processo de ETL e como ele garante que os dados estejam em conformidade com as regulamentações e políticas internas da organização?

A) Realizar a compressão dos dados para otimização de espaço de armazenamento
B) Monitorar continuamente a segurança dos dados durante todas as fases do ETL
C) Executar consultas de alta performance nos dados conformados
D) Facilitar a integração de dados de fontes externas sem necessidade de validação
E) Garantir que os dados carregados no data warehouse estejam em conformidade com as regulamentações e políticas internas, aplicando regras de conformidade específicas durante o processo de transformação

Gabarito: E

Comentários: O subsistema de gerenciamento de conformidade garante que os dados carregados estejam em conformidade com as regulamentações e políticas internas, aplicando regras específicas durante a transformação para assegurar a integridade e conformidade dos dados.

9. No contexto de Master Data Management (MDM), qual é uma prática essencial para garantir a qualidade dos dados mestres?

A) Realizar a compressão dos dados
B) Executar consultas em tempo real

11225354498 - Maria Vitória Gonçalves Vieira

C) Implementar regras de negócios e validação de dados
D) Facilitar a migração de dados para o cloud
E) Garantir backups frequentes dos dados

Gabarito: C

Comentários: Uma prática essencial no contexto de Master Data Management (MDM) é implementar regras de negócios e validação de dados para assegurar que os dados mestres sejam consistentes, precisos e confiáveis.

10. Complete a frase a seguir: A etapa de _____ no processo de ETL é responsável por coletar dados de várias fontes e garantir que eles sejam capturados de forma eficiente, sem realizar alterações iniciais antes da transformação e carga.

A) extração
B) transformação
C) validação
D) integração
E) padronização

Gabarito: A

Comentários: No processo de ETL, a etapa de extração é fundamental para capturar os dados de diferentes fontes, garantindo que eles sejam coletados de maneira eficiente antes de passar pela transformação e carga.

1.B	2.E	3.A	4.C	5.A
6.D	7.B	8.E	9.C	10.A

11225354498 - Maria Vitória Gonçalves Vieira

ESSA LEI TODO MUNDO CONHECE:
PIRATARIA É CRIME.

Mas é sempre bom revisar o porquê e como você pode ser prejudicado com essa prática.

1. 

Professor investe seu tempo para elaborar os cursos e o site os coloca à venda.

2. 

Pirata divulga ilicitamente (grupos de rateio), utilizando-se do anonimato, nomes falsos ou laranjas (geralmente o pirata se anuncia como formador de "grupos solidários" de rateio que não visam lucro).

3. 

Pirata cria alunos fake praticando falsidade ideológica, comprando cursos do site em nome de pessoas aleatórias (usando nome, CPF, endereço e telefone de terceiros sem autorização).

4. 

Pirata compra, muitas vezes, clonando cartões de crédito (por vezes o sistema anti-fraude não consegue identificar o golpe a tempo).

5. 

Pirata fere os Termos de Uso, adultera as aulas e retira a identificação dos arquivos PDF (justamente porque a atividade é ilegal e ele não quer que seus fakes sejam identificados).

6. 

Pirata revende as aulas protegidas por direitos autorais, praticando concorrência desleal e em flagrante desrespeito à Lei de Direitos Autorais (Lei 9.610/98).

7. 

Concurseiro(a) desinformado participa de rateio, achando que nada disso está acontecendo e esperando se tornar servidor público para exigir o cumprimento das leis.

8. 

O professor que elaborou o curso não ganha nada, o site não recebe nada, e a pessoa que praticou todos os ilícitos anteriores (pirata) fica com o lucro.



Deixando de lado esse mar de sujeira, aproveitamos para agradecer a todos que adquirem os cursos honestamente e permitem que o site continue existindo.